

ÉCOLE POLYTECHNIQUE

Promotion X2023

DANIEL Nils

RAPPORT DE STAGE DE RECHERCHE

Apprentissage de variété pour des données asymétriques

RAPPORT NON CONFIDENTIEL

Option	Département d'Informatique
Champ	Data Science
Enseignant référent	OUDOT Steve
Tuteur de stage dans l'organisme	DAGÈS Tomas
Dates du stage	07/04/2026 – 01/08/2026
Organisme d'accueil	Université Technique de Munich
Adresse de l'organisme	Boltzmannstraße 3, 85748 Garching bei München - Allemagne


Déclaration d'intégrité relative au plagiat

Je soussigné(e) DANIEL Nils certifie sur l'honneur :

1. Que les résultats décrits dans ce rapport sont l'aboutissement de mon travail.
2. Que je suis l'auteur de ce rapport.
3. Que je n'ai pas utilisé des sources ou résultats tiers sans clairement les citer et les référencer selon les règles bibliographiques préconisées.

Je déclare que ce travail ne peut être suspecté de plagiat.

Date : 1^{er} juillet 2026

Signature :.....

Résumé

Les méthodes classiques de réduction de dimension et de manifold learning reposent généralement sur des distances symétriques et produisent des embeddings dans un espace euclidien. Elles sont donc mal adaptées à des données contenant une information asymétrique, comme des graphes orientés ou des temps de trajet dans un champ de courant. La méthode récente Finsler-MDS répond à cette limite en remplaçant la métrique euclidienne de l'espace d'arrivée par une métrique de Randers asymétrique.

Ce stage développe et étudie deux extensions naturelles de cette méthode. La première consiste à remplacer la métrique de Randers par des métriques de Finsler plus riches, en particulier la métrique de Matsumoto. La seconde consiste à utiliser, dans l'espace d'arrivée, les distances géodésiques le long de la variété discrète formée par les points de l'embedding, plutôt que les distances directes.

Ce rapport présente une analyse théorique de ces extensions, leur implémentation algorithmique, ainsi que des validations sur des données synthétiques contrôlées. Des expériences exploratoires sont également menées sur des données réelles de biologie unicellulaire, notamment en RNA-velocity et en inférence de trajectoires. Les résultats obtenus dans les cas contrôlés confirment certains avantages des extensions proposées, tandis que les évaluations sur les cas biologiques restent plus mitigées et devront être consolidées.

Abstract

Classical dimensionality reduction and manifold learning methods generally rely on symmetric distances and produce embeddings in Euclidean spaces. They are therefore not well suited to data containing asymmetric information, such as directed graphs or travel times in a vector field. The recent Finsler-MDS framework addresses this limitation by replacing the Euclidean metric in the embedding space with an asymmetric Randers metric.

This internship develops and studies two natural extensions of this method. The first one replaces the Randers metric with richer Finsler metrics, in particular the Matsumoto metric. The second one uses geodesic distances in the embedding space, computed along the discrete manifold formed by the embedded points, instead of direct pairwise distances.

This report presents the theoretical analysis of these extensions, their algorithmic implementation, and controlled validation experiments on synthetic datasets. Exploratory experiments are also conducted on real single-cell biological data, in particular RNA-velocity and trajectory inference datasets. The results obtained on controlled cases confirm some advantages of the proposed extensions, while evaluations on biological cases remain more mixed and require further consolidation.

Table des matières

1	Introduction	5
2	État de l’art	7
2.1	Multidimensional Scaling (MDS)	7
2.2	Autres méthodes de réduction de dimension	8
2.3	Finsler-MDS et géométrie asymétrique	9
2.4	Distances géodésiques dans l’espace d’arrivée et optimisation	11
2.5	Données biologiques unicellulaires	12
3	Propriétés géométriques de Matsumoto	13
3.1	Cadre et notations	13
3.2	Interprétation <i>slope-of-a-mountain</i>	15
3.3	Géodésiques de Matsumoto	17
3.4	Régime non convexe	21
3.5	Synthèse	23
4	Optimisation algorithmique	24
4.1	Distances directes : SMACOF et descente de gradient	24
4.2	Path-Frozen Alternating Optimization	26
4.3	Approches différentiables	28
4.4	Heuristiques de passage à l’échelle	29
5	Expériences et résultats	31
5.1	Données synthétiques	31
5.2	Inférence de trajectoire : Paul15	33
5.3	RNA-velocity : Pancreas	34
6	Conclusion et perspectives	38
	Annexes	44
A	Modèles de marche de Tobler et Minetti	44
B	Mesures sur les heuristiques de Path-Frozen	45
C	Métriques d’évaluation pour RNA-velocity	48

1 Introduction

Les jeux de données modernes consistent généralement en des vecteurs en haute, voire très haute dimension. Cette dimension élevée empêche de les visualiser directement comme pour des données en 2D ou 3D, et peut aussi représenter un coût important en temps de calcul ou en mémoire pour les algorithmes qui les utilisent. Des techniques de réduction de dimension existent donc pour représenter ces données dans un espace de plus faible dimension, tout en conservant autant que possible les informations importantes du jeu de données d'origine. On utilisera dans la suite le terme d'embedding pour désigner ces représentations des points en basse dimension.

Une grande partie des méthodes de réduction de dimension repose, explicitement ou implicitement, sur la notion de distance, ou plus généralement de dissimilarité, entre les points. Certains algorithmes peuvent ainsi ne pas prendre en entrée les coordonnées des points, mais directement la matrice de dissimilarités D , où D_{ij} mesure à quel point le point i est différent du point j . C'est notamment le principe général du multidimensional scaling (MDS), qui cherche des points en basse dimension dont les distances reproduisent au mieux les dissimilarités données.

Toutefois, utiliser directement les distances euclidiennes entre les points de l'espace d'origine ne permet pas toujours de capturer la structure pertinente des données. C'est l'une des motivations du manifold learning, ou apprentissage de variétés. L'idée générale est que les données, bien qu'elles soient décrites dans un espace de grande dimension, peuvent se concentrer autour d'une structure de plus faible dimension, que l'on peut modéliser comme une variété. Sur une telle structure, la distance pertinente entre deux points n'est pas nécessairement la distance directe dans l'espace ambiant, mais plutôt la distance géodésique, c'est-à-dire la longueur du plus court chemin parmi ceux restant à l'intérieur de la variété. Par exemple, deux extrémités d'une courbe en U peuvent être proches dans l'espace ambiant, mais éloignées si l'on suit la courbe. En pratique, cette variété n'est pas connue explicitement : on ne dispose que d'un nuage de points. Des méthodes comme Isomap approximent alors les distances géodésiques par des plus courts chemins dans un graphe de voisinage construit sur les données, puis utilisent ces distances comme dissimilarités pour produire un embedding.

Ces approches restent cependant fondées sur des distances symétriques. Dans un espace euclidien ou riemannien classique, la distance entre deux points ne dépend pas du sens dans lequel on la parcourt : $d(i, j) = d(j, i)$. Il existe pourtant de nombreuses situations où cette hypothèse est restrictive. Dans un graphe orienté, une relation peut exister de i vers j sans exister de j vers i . Sur une carte avec un courant ou du vent, le temps de trajet entre deux points peut être différent à l'aller et au retour. De même, certaines données dynamiques contiennent une information directionnelle que l'on peut vouloir conserver. Dans ces situations, remplacer les relations orientées par des distances symétriques revient à ignorer une partie de l'information disponible.

La réduction de dimension pour des données asymétriques reste peu explorée par rapport au cas symétrique. La méthode récente Finsler-MDS propose une manière de traiter ce problème en

reprenant l'idée du MDS, mais en remplaçant la distance euclidienne dans l'espace d'arrivée par une métrique de Finsler asymétrique. Une métrique de Finsler associe un coût à un déplacement dans une direction donnée, et ce coût peut dépendre du sens du déplacement. Il devient alors possible d'avoir $F(u) \neq F(-u)$, et donc de représenter des dissimilarités asymétriques $D_{ij} \neq D_{ji}$. Dans sa formulation initiale, Finsler-MDS utilise une métrique de Randers uniforme. Cette métrique constitue un choix simple et calculable : elle ajoute à la norme euclidienne un terme linéaire dépendant de la projection du déplacement sur une direction privilégiée. Elle permet donc d'introduire une asymétrie dans l'espace d'arrivée tout en conservant une expression simple des distances.

Ce cadre ouvre cependant plusieurs questions. La métrique de Randers n'est qu'un exemple particulier de métrique de Finsler. Elle modélise une asymétrie simple, de type courant uniforme, mais ne permet pas d'explorer toute la diversité des comportements possibles en géométrie de Finsler. L'une des premières directions étudiées dans ce stage consiste donc à remplacer la métrique de Randers par des métriques de Finsler plus riches. Nous nous concentrons en particulier sur la métrique de Matsumoto, dont la dépendance directionnelle est non linéaire et qui admet une interprétation comme temps de déplacement le long d'une pente sous l'effet de la gravité. Cette métrique peut produire des comportements géométriques différents de ceux de Randers, par exemple en privilégiant des chemins de pente plus régulière, et permet donc d'étudier ce que peut apporter une métrique de Finsler plus riche dans le cadre de Finsler-MDS.

Cette première extension soulève une seconde question. Certaines métriques de Finsler, en particulier Matsumoto, s'interprètent naturellement comme un coût de déplacement le long d'un chemin. Or Finsler-MDS mesure uniquement la distance directe entre deux points de l'embedding. Cette distance directe peut être suffisante pour optimiser un stress, mais elle ne permet pas d'interpréter les trajectoires visibles dans l'embedding comme des chemins parcourus le long de la structure affichée. Nous avons donc étudié une extension plus exploratoire, consistant à remplacer les distances directes dans l'espace d'arrivée par des distances géodésiques calculées sur un graphe construit dans l'embedding. Les arêtes de ce graphe sont mesurées avec la métrique de Finsler choisie, et la distance entre deux points est définie comme le coût du plus court chemin entre eux. Cette extension permet d'interpréter l'embedding comme une carte de chemins admissibles au sens du modèle, et non plus seulement comme un ensemble de distances directes entre paires de points.

Ces deux directions posent toutefois des difficultés différentes. Pour les métriques de Finsler autres que Randers, le domaine reste peu exploré dans le contexte du manifold learning asymétrique. Il faut donc étudier leurs propriétés géométriques, leurs conditions de validité et leur comportement sur des exemples contrôlés. Pour les distances géodésiques dans l'espace d'arrivée, la difficulté est principalement algorithmique. À notre connaissance, ce type d'objectif géodésique dans l'espace d'arrivée n'est pas standard, même dans le cas euclidien symétrique. Les distances dépendent de plus courts chemins dans un graphe construit sur l'embedding, mais ce graphe et ces chemins changent lorsque les points de l'embedding sont déplacés. Cette extension a donc nécessité d'étudier plusieurs stratégies d'optimisation, allant de relaxations différentiables de plus courts chemins à une approximation *Path-Frozen* plus pragmatique.

Les contributions principales de ce stage sont les suivantes. Premièrement, nous étudions l'utilisation de métriques de Finsler alternatives à Randers dans Finsler-MDS, en particulier la métrique de Matsumoto, et analysons certaines de ses propriétés géométriques. Deuxièmement, nous proposons une extension de MDS et de Finsler-MDS aux distances géodésiques dans l'espace d'arrivée, que nous appellerons GeoMDS. Troisièmement, nous développons une implémentation algorithmique de cette extension, notamment à travers une approche Path-Frozen pour l'optimisation géodésique, ainsi que plusieurs heuristiques destinées à réduire le coût de calcul. Quatrièmement, nous identifions et corrigeons une erreur dans l'algorithme Finsler-SMACOF proposé pour Finsler-MDS. Enfin, nous validons certaines propriétés de ces méthodes sur des données synthétiques contrôlées et nous menons des expériences exploratoires sur deux jeux de données de biologie unicellulaire, en inférence de trajectoires et en RNA-velocity.

Ce rapport est rédigé dans le cadre d'une soutenance anticipée, un mois avant la fin effective du stage. Les résultats présentés doivent donc être compris comme l'état actuel du travail. En particulier, les résultats expérimentaux sur données biologiques doivent être lus comme des évaluations exploratoires, encore en cours de consolidation.

La suite du rapport est organisée comme suit. La section 2 présente l'état de l'art sur la réduction de dimension, le manifold learning, les embeddings asymétriques et les applications biologiques considérées. La section 3 présente notre étude théorique de la géométrie de Matsumoto et des chemins géodésiques dans notre cadre de Matsumoto canonique. La section 4 décrit les choix d'optimisation algorithmique utilisés, en particulier les optimiseurs sur distances géodésiques pour GeoMDS et les heuristiques choisies. Enfin, la section 5 présente les résultats de tests obtenus sur données synthétiques et sur données biologiques.

2 État de l'art

Cette section présente les travaux scientifiques sur lesquels s'appuie le stage. Nous détaillerons d'abord le Multidimensional Scaling (MDS), puis nous aborderons les autres méthodes de réduction de dimension populaires. Nous nous intéresserons ensuite aux méthodes d'embedding asymétrique fondées sur la géométrie de Finsler, avant de discuter l'utilisation de distances géodésiques dans l'espace d'arrivée. Enfin, nous présenterons les domaines biologiques qui seront utilisés comme cas d'application.

2.1 Multidimensional Scaling (MDS)

MDS est la méthode de réduction de dimension qui sert de base à nos travaux. Son objectif est de trouver un embedding dans la dimension choisie dont les distances reproduisent une matrice de dissimilarités donnée. Il faut distinguer deux formulations souvent appelées MDS. Le MDS classique, dû notamment à Torgerson [1952], est une méthode spectrale appliquée à une matrice de distances carrées. Lorsque ces distances proviennent de distances euclidiennes exactes entre points centrés, il retrouve essentiellement le même sous-espace que l'ACP (Analyse en Composantes Principales). Le MDS métrique, associé notamment aux travaux de Shepard [1962] et Kruskal [1964], cherche directement à minimiser un stress mesurant l'écart entre les distances

de l'embedding et les dissimilarités cibles. C'est cette deuxième formulation qui correspond au cadre de ce rapport. Le stress en question est :

$$\sum_{i < j} w_{ij} (\|y_i - y_j\| - D_{ij})^2,$$

où D_{ij} est la dissimilarité cible entre les points i et j , et w_{ij} est un poids associé à cette paire, tous deux étant supposés symétriques. La distance d'arrivée est la norme $\|y_i - y_j\|$, donc elle est également symétrique. En dehors de cela, la formulation reste très générale : les dissimilarités D et les poids w peuvent être arbitraires, tant qu'ils sont non négatifs.

L'optimisation du stress métrique est souvent réalisée par l'algorithme SMACOF, pour *Scaling by MAjorizing a COmplicated Function*. Cette famille de méthodes repose sur la construction d'une fonction auxiliaire qui majore le stress courant et qui est plus facile à minimiser de Leeuw [1977], de Leeuw and Mair [2009]. SMACOF est conçu pour le stress MDS euclidien standard. Si cette formulation est modifiée, par exemple en utilisant une autre métrique dans l'espace d'arrivée, une nouvelle majoration doit donc être dérivée.

Une autre méthode centrale pour ce rapport est Isomap [Tenenbaum et al., 2000]. Isomap ne propose pas une nouvelle méthode d'optimisation de l'embedding : il utilise le MDS classique, mais propose une manière différente de construire la matrice de dissimilarités. L'idée est que les distances euclidiennes directes dans l'espace d'origine peuvent être trompeuses lorsque les données vivent sur une variété courbée ou repliée. Il est alors plus pertinent de considérer les distances géodésiques le long de cette variété. Pour les approximer, Isomap construit un graphe de voisinage où chaque point est relié à ses k voisins les plus proches, ou k NN (*k-nearest neighbors*), par une arête dont le poids est la distance les séparant. La distance entre deux points le long du graphe, c'est-à-dire la longueur du plus court chemin entre eux, est utilisée comme dissimilarité approxinant la distance géodésique. Dans nos expériences, comme dans certains usages de Finsler-MDS, ce type de construction peut servir à définir les dissimilarités. Notre extension utilisant les distances géodésiques dans l'espace d'arrivée en est également inspirée.

2.2 Autres méthodes de réduction de dimension

Toutes les méthodes d'embedding ne cherchent pas à préserver explicitement toutes les distances entre paires de points. Nos travaux ne sont pas fondés sur ces méthodes, mais elles constituent des points de comparaison incontournables en réduction de dimension.

Mentionnons d'abord la méthode la plus classique, l'ACP (PCA en anglais), introduite dans ses principes par Pearson [1901] puis Hotelling [1933]. L'ACP est une méthode spectrale qui projette les données dans un sous-espace de la dimension voulue, en conservant autant que possible la variance des données. Elle est très rapide et relativement stable, mais elle est incapable de déplier des structures non linéaires. Elle reste souvent utilisée comme prétraitement avant des méthodes plus coûteuses, par exemple pour passer de dizaines de milliers de dimensions à quelques dizaines.

Plus récente, t-SNE [van der Maaten and Hinton, 2008] est une baseline importante en visualisation de données de grande dimension. Elle représente les similarités entre points par des probabilités dans l'espace d'origine et dans l'espace d'arrivée, puis cherche à rapprocher ces distributions. La méthode est particulièrement efficace pour visualiser des clusters. En revanche, les distances globales entre clusters, la taille relative des groupes ou les distances entre points éloignés ne doivent pas être interprétées trop directement.

UMAP [McInnes et al., 2018] est aujourd'hui l'une des méthodes de visualisation les plus utilisées. Elle construit un graphe de voisinage pondéré dans l'espace d'origine, puis optimise un embedding de faible dimension en comparant ce graphe à un graphe construit dans l'espace d'arrivée. UMAP est rapide, robuste en pratique, et produit souvent des visualisations plus lisibles que les méthodes fondées uniquement sur des distances globales. Cependant, comme t-SNE, UMAP privilégie les voisinages locaux, et les distances globales peuvent être déformées.

Ces deux dernières méthodes sont des références essentielles pour la visualisation, mais elles répondent à un objectif différent de celui du MDS et de Finsler-MDS. Elles cherchent avant tout un embedding lisible et localement cohérent, alors que MDS et ses extensions cherchent à produire des embeddings où les distances sont interprétables. Selon le contexte, la clarté visuelle des clusters ou la préservation des distances peuvent être préférables. Ce rapport se place principalement dans cette seconde logique.

2.3 Finsler-MDS et géométrie asymétrique

La géométrie riemannienne généralise la géométrie euclidienne en autorisant une norme qui dépend du point de la variété. Localement, cette norme est définie par une matrice symétrique définie positive $M(x)$, ce qui donne une longueur locale de la forme

$$\|u\|_{M(x)} = \sqrt{u^T M(x) u}.$$

Cela peut s'interpréter comme une mise à l'échelle des différentes coordonnées, éventuellement après rotation locale du système de coordonnées. Cette formulation reste cependant symétrique : la longueur de u est égale à celle de $-u$.

La géométrie de Finsler généralise encore ce cadre en remplaçant cette norme quadratique par une fonction plus générale $F(x, u)$, positive, positivement homogène en u , et convexe en la direction. Comme seule l'homogénéité positive est demandée, et pas l'homogénéité classique, une métrique de Finsler peut être asymétrique, c'est-à-dire vérifier $F(x, u) \neq F(x, -u)$. C'est cette propriété qui permet de l'utiliser pour représenter des dissimilarités orientées. Ces métriques ont été utilisées pour modéliser des phénomènes asymétriques en analyse de formes, en traitement d'images, en propagation de fronts et dans certains modèles de réseaux de neurones [Weber et al., 2024, Chen et al., 2017, Dagès et al., 2025a, Gahtan et al., 2026, Roddenberry and Baraniuk, 2026].

Un exemple classique de métrique de Finsler asymétrique est la métrique de Randers [1941].

Elle s'écrit comme la somme d'une norme riemannienne et d'un terme linéaire en la direction :

$$F_R(x, u) = \|u\|_{M(x)} + \omega(x)^T u.$$

Pour obtenir une métrique de Finsler régulière, on doit avoir $\|\omega(x)\|_{M(x)^{-1}} < 1$. La métrique de Randers peut s'interpréter comme un coût de déplacement sous l'effet d'un champ de courant ou de vent dans la direction de $-\omega(x)$, bien qu'en toute rigueur, l'interprétation en termes de navigation de Zermelo nécessite un choix approprié de norme riemannienne $M(x)$ Bao et al. [2004]. Dans Finsler-MDS, on utilise cependant surtout une version canonique plus simple, avec $M = I$ et un vecteur ω constant, orienté vers le haut : selon l'axe y en 2D ou l'axe z en 3D. Les déplacements dans le sens de ω sont alors pénalisés, tandis que les déplacements dans le sens opposé sont favorisés.

Le papier Finsler-MDS de Dagès et al. [2025b] utilise cette idée pour étendre le MDS au cas des dissimilarités asymétriques, en munissant l'espace d'arrivée de cette métrique de Randers canonique. Le stress devient :

$$\sum_{i \neq j} w_{ij} (F_R(y_j - y_i) - D_{ij})^2.$$

Avec cette distance asymétrique, une dissimilarité telle que $D_{ij} < D_{ji}$ peut alors être représentée en plaçant le point i au-dessus de j : le déplacement de i vers j est moins coûteux que dans le sens inverse. Le papier propose aussi une adaptation de SMACOF au cas Randers. Cette nouvelle majoration profite de l'expression simple de la métrique de Randers et ne peut donc pas directement être étendue à d'autres métriques de Finsler.

Le cadre de Finsler-MDS reste cependant récent et encore peu exploré. Randers est un choix simple et calculable, mais il ne représente qu'un cas particulier de métrique de Finsler. Sa simplicité pourrait donc limiter sa capacité à représenter des dissimilarités présentant une asymétrie plus complexe.

C'est ce qui motive l'étude de la métrique de Matsumoto [1989], une autre métrique classique en géométrie de Finsler, bien que moins étudiée et utilisée que Randers. Cette métrique, parfois appelée *slope-of-a-mountain metric*, a été introduite pour modéliser un temps de déplacement sur une pente sous l'effet de la gravité. Elle s'écrit, dans le cadre général :

$$F_M(x, u) = \frac{\|u\|_{M(x)}^2}{\|u\|_{M(x)} - \omega(x)^T u}.$$

La condition de validité est ici plus restrictive que pour Randers : dans le cas général, elle impose $\|\omega(x)\|_{M(x)^{-1}} < 1/2$. Dans ce rapport, nous nous limiterons principalement au cas canonique où $M(x) = I$ et où ω est uniforme, orienté selon l'axe vertical de l'embedding. L'étude de métriques non uniformes pourra constituer une extension future.

Comme Randers, Matsumoto pénalise les déplacements dans le sens de ω et favorise les déplacements dans le sens opposé. La différence est que cette dépendance est non linéaire : lorsque la direction du déplacement se rapproche de celle de ω , la distance selon Matsumoto augmente de plus en plus vite. Cette non-linéarité rend Matsumoto intéressante pour Finsler-MDS, car elle peut produire des comportements géométriques différents de ceux de Randers, par exemple des géodésiques qui ne coïncident plus nécessairement avec les géodésiques euclidiennes. Nous avons identifié d'autres propriétés géométriques dans le cas canonique, qui seront présentées dans la section suivante.

Un travail plus récent, *Harnessing Data Asymmetry : Manifold Learning in the Finsler World* Dagès et al. [2026], prolonge la logique de Finsler-MDS en proposant notamment des variantes Finsler de t-SNE et UMAP, utilisant elles aussi un espace de Randers canonique. Contrairement à Finsler-MDS, ces méthodes ne partent pas d'une matrice de dissimilarités asymétriques arbitraires, mais cherchent surtout à exploiter les asymétries qui apparaissent dans les pipelines de manifold learning, notamment à cause de la densité non uniforme des données, et qui sont habituellement symétrisées. Ces asymétries ne sont pas centrales dans ce rapport, mais elles constituent une autre source possible de dissimilarités asymétriques et donc un autre cas d'application potentiel de Finsler-MDS et de ses extensions. Par ailleurs, Finsler-t-SNE et Finsler-UMAP restent des travaux proches, et Finsler-UMAP servira de comparaison exploratoire dans nos expériences.

Mentionnons enfin qu'il existe d'autres approches de réduction de dimension pour données asymétriques, qui ne reposent pas sur la géométrie de Finsler. On peut notamment citer les modèles d'asymmetric MDS [Okada and Imaizumi, 1987], ainsi que plusieurs méthodes d'embedding de graphes orientés, par exemple fondées sur des opérateurs de type Laplacien [Perrault-Joncas and Meila, 2011, Fanuel et al., 2018, Ou et al., 2016]. Toutefois ces travaux visent le plus souvent des graphes orientés ou des proximités spécifiques, alors que Finsler-MDS conserve une formulation de type MDS où les dissimilarités asymétriques sont approximées par une distance directionnelle explicite dans l'embedding. Dans ce rapport, nous nous concentrons sur ce cadre Finsler-MDS et sur ses extensions.

2.4 Distances géodésiques dans l'espace d'arrivée et optimisation

Dans la suite, on appellera distance directe la distance mesurée sur le segment reliant deux points de l'espace d'arrivée. Cette distance peut être euclidienne, ou bien mesurée avec une métrique de Finsler. Par opposition, on appellera distance géodésique la longueur du plus court chemin contraint à rester dans la variété considérée. En toute rigueur, la distance directe peut être vue comme une distance géodésique si l'on considère comme variété l'espace tout entier, mais nous réservons ce terme aux variétés qui entourent nos nuages de points, qu'il s'agisse des données d'origine ou des embeddings. Comme dans Isomap, nous approximations les variétés et les calculs de distances géodésiques par des graphes de voisinage kNN, dont les arêtes sont pondérées par la distance, éventuellement différente selon le sens. Des méthodes continues de calcul de géodésiques comme Fast Marching ou GEORCE existent aussi, mais elles sont peu adaptées à notre cas, où l'on ne dispose que d'un nuage de points, pas d'une géométrie connue

ou d’un maillage régulier, et où ce nuage bouge durant l’optimisation. Notre extension GeoMDS vise à créer des embeddings tels que les distances géodésiques le long de la variété formée par ces embeddings correspondent à la matrice de dissimilarités donnée.

À notre connaissance, ce type d’objectif — optimiser un embedding en recalculant des distances de chemin sur la structure mobile formée par les points — n’a pas été étudié en manifold learning. Cette extension introduit des difficultés d’optimisation par rapport au MDS classique. Si un chemin entre deux points est fixé, sa longueur est simplement une somme de longueurs d’arêtes, et cette somme peut être différenciée par rapport aux positions des points. Mais le chemin optimal lui-même dépend des positions. Lorsque les points se déplacent, les poids des arêtes changent, ce qui peut modifier le plus court chemin. De plus, si le graphe de voisinage est recalculé à chaque étape, les arêtes elles-mêmes peuvent apparaître ou disparaître lorsque les relations de plus proches voisins changent. La distance géodésique dépend donc des positions des points de manière non lisse, voire discontinue.

Il existe des méthodes rendant le calcul de plus court chemin sur un graphe différentiable. Des méthodes comme DataSP Lahoud et al. [2024] s’appuient sur une relaxation de l’algorithme de Floyd-Warshall, qui sert à calculer les plus courts chemins pour toutes les paires, en le rendant différentiable par le remplacement des minimums par la fonction soft-min. Une idée similaire peut être appliquée à l’algorithme de Bellman-Ford [Bellman, 1958]. Ces relaxations permettent de propager un gradient à travers le calcul des distances sur un graphe fixé. Cependant, elles ne prennent pas en compte le fait que, dans notre cas, le graphe lui-même change à cause des arêtes kNN. De plus, Floyd-Warshall et Bellman-Ford sont plus coûteux que Dijkstra pour calculer des distances all-to-all sur un graphe kNN sparse. Dijkstra, quant à lui, est difficile à relaxer de la même manière, car il repose sur une file de priorité et sur une sélection gloutonne du prochain sommet à figer, plutôt que sur une simple succession de minimums locaux remplaçables par des soft-min.

Une relaxation différentiable du kNN serait envisageable via des opérateurs de type SOFT top-k [Xie et al., 2020], mais elle conduirait probablement à un graphe dense ou quasi dense, avec un coût difficilement compatible avec notre objectif. Dans ce rapport, nous adoptons donc une approche plus pragmatique fondée sur le recalcul périodique du graphe. Cette idée sera utilisée dans nos implémentations de soft-Floyd-Warshall et soft-Bellman-Ford, et surtout dans l’algorithme *Path-Frozen Alternating Optimization* proposé en section 4.

2.5 Données biologiques unicellulaires

Les données de biologie unicellulaire constituent un domaine d’application naturel pour les méthodes de réduction de dimension. Les profils d’expression génique mesurés par séquençage d’ARN unicellulaire comportent typiquement plusieurs dizaines de milliers de variables ; il est donc courant d’appliquer des méthodes comme ACP en pré-traitement, et d’effectuer des visualisations via t-SNE ou UMAP. Nous nous sommes donc intéressés à ce domaine pour tester sur des données réelles Finsler-MDS et nos extensions.

Ces données unicellulaires sont notamment utilisées pour étudier des processus de différenciation

cellulaire comme dans l'inférence de trajectoire (Trajectory Inference), où l'on cherche à reconstruire une progression ou un « pseudotime » à partir d'observations ponctuelles. Des méthodes comme Monocle [Trapnell et al., 2014], PAGA [Wolf et al., 2019] ou PHATE [Moon et al., 2019] s'inscrivent dans ce contexte. Cette idée motive GeoMDS : si les trajectoires biologiques sont interprétées comme des chemins dans le nuage de points, il peut être utile de construire un embedding dont les distances de chemin restent cohérentes avec ces trajectoires. C'est ce que nous explorons de manière préliminaire sur le dataset Paul15 [Paul et al., 2015].

RNA-velocity fournit une autre source d'information, cette fois directionnelle. Introduite par La Manno et al. [2018] puis généralisée dans scVelo par Bergen et al. [2020], elle estime pour chaque cellule une direction locale d'évolution à partir des ARN épissés et non épissés. Cette information est souvent projetée sur un embedding déjà construit, mais certaines méthodes comme VeloViz [Atta et al., 2022] cherchent à l'intégrer plus directement dans la visualisation. Notre approche suit une motivation proche, mais en transformant la vitesse en dissimilarités asymétriques que l'on cherche ensuite à représenter par Finsler-MDS et ses variantes. Les expériences biologiques présentées dans ce rapport doivent toutefois être comprises comme exploratoires.

Nous reviendrons sur nos expériences sur ces données biologiques en fin de rapport. Après ce positionnement dans l'état de l'art, nous abordons dans la section suivante l'étude des extensions que nous proposons, en étudiant les propriétés géométriques de la métrique de Matsumoto.

3 Propriétés géométriques de Matsumoto

Dans cette section, nous présentons notre étude théorique de la métrique de Matsumoto. Nous rappellerons d'abord certains résultats connus sur cette métrique, puis nous étudierons plusieurs propriétés géométriques du cas canonique uniforme utilisé dans ce rapport. Notre objectif est d'identifier en quoi Matsumoto peut induire une géométrie plus riche que la métrique de Randers, afin de comprendre ce que son utilisation dans Finsler-MDS et son extension géodésique pourrait apporter.

Nous commencerons par poser le cadre théorique et les notations utilisées dans la suite. Nous discuterons ensuite l'interprétation de Matsumoto comme temps de trajet sur une pente, avant d'étudier les chemins géodésiques associés à la métrique canonique. Enfin, nous analyserons le régime non convexe $\|\omega\| > 1/2$ et ses comportements géométriques.

3.1 Cadre et notations

On considère un ensemble de points $Y = (y_i)_{1 \leq i \leq n}$ dans l'espace d'arrivée, généralement de dimension 2 ou 3. Les dissimilarités cibles, que l'on souhaite reproduire dans notre embedding, sont notées D_{ij} , et peuvent être asymétriques dans notre cas : $D_{ij} \neq D_{ji}$. On note aussi $w_{ij} \geq 0$ les poids associés aux paires, supposés symétriques.

Dans le cas direct - i.e. en dehors de l'extension GeoMDS - le stress que Finsler-MDS minimise

s'écrit

$$\sigma_{\text{dir}}(Y) = \sum_{i \neq j} w_{ij} (F(y_j - y_i) - D_{ij})^2,$$

où F est la métrique Finslérienne utilisée dans l'espace d'arrivée. Selon les cas, F pourra être la norme euclidienne, la métrique de Randers canonique ou la métrique de Matsumoto canonique. Il s'agira donc d'une métrique uniforme, alors que dans le cas général une métrique de Finsler dépend du point considéré. Lorsque l'on utilise la norme euclidienne, on retrouve l'objectif du MDS métrique standard, si ce n'est qu'on a autorisé D à être asymétrique.

On s'intéressera aussi à la version géodésique de cet objectif, utilisée par notre extension GeoMDS. Pour un chemin $\gamma : [0, 1] \rightarrow \mathbb{R}^d$, sa longueur selon F est définie par

$$L_F(\gamma) = \int_0^1 F(\gamma(t), \dot{\gamma}(t)) dt.$$

La distance géodésique entre deux points p et q est alors

$$d_F^{\text{geo}}(p, q) = \inf_{\gamma(0)=p, \gamma(1)=q} L_F(\gamma),$$

où l'infimum est pris sur les chemins restant à l'intérieur de la variété que l'on considère. Si l'espace entier - qui est convexe - est autorisé et si la métrique est uniforme, la géodésique sera simplement le segment. En effet l'inégalité triangulaire implique qu'un détour ne peut qu'augmenter la mesure. Dans notre cadre, les chemins sont contraints à suivre la variété formée par les points - que l'on approxime en pratique par un graphe de voisinage mais ce n'est pas l'objet de cette partie. L'objectif géodésique correspondant est donc

$$\sigma_{\text{geo}}(Y) = \sum_{i \neq j} w_{ij} (d_F^{\text{geo}}(y_i, y_j) - D_{ij})^2.$$

Les métriques de Randers et de Matsumoto appartiennent à la famille des (α, β) -métriques [Shen, 2001]. Dans ce cadre, une métrique de Finsler s'écrit à partir d'une norme riemannienne α et d'une 1-forme β sous la forme

$$F(u) = \alpha(u) \phi\left(\frac{\beta(u)}{\alpha(u)}\right).$$

Notre cadre se limite au cas canonique uniforme, où

$$\alpha(u) = \|u\|, \quad \beta(u) = \omega^T u, \quad s(u) = \frac{\beta(u)}{\alpha(u)},$$

avec le vecteur ω constant et orienté selon l'axe vertical (l'axe y en 2D ou l'axe z en 3D). Si θ désigne l'angle entre u et ω , alors

$$s(u) = \|\omega\| \cos(\theta).$$

La métrique de Randers canonique correspond à

$$F_R(u) = \|u\| + \omega^T u = \|u\|(1 + s),$$

tandis que la métrique de Matsumoto canonique correspond à

$$F_M(u) = \frac{\|u\|^2}{\|u\| - \omega^T u} = \|u\| \frac{1}{1 - s}.$$

On a donc

$$\phi_R(s) = 1 + s, \quad \phi_M(s) = \frac{1}{1 - s}.$$

3.2 Interprétation *slope-of-a-mountain*

La métrique de Matsumoto a été introduite pour modéliser un temps de déplacement sur une pente sous l'effet de la gravité [Matsumoto, 1989, Chansri et al., 2020]. Lorsqu'on se déplace sur une pente, on choisit la direction du mouvement mais la pente nous ralentit ou nous accélère - c'est un effet scalaire sur notre vitesse, contrairement au modèle de navigation de Zermelo-Randers où le vent ou le courant s'additionne vectoriellement à notre vitesse. Pour retrouver la formule de Matsumoto, on considère un modèle physique simplifié : un mobile se déplace le long d'une pente sous l'effet de sa force motrice F_{mot} ainsi que de son poids $m\vec{g}$ et d'une forme de frottement linéaire $k\vec{v}$. On suppose aussi que le mouvement est contraint dans le sens de la force motrice, par exemple par un contact avec des rails. La figure 1 schématise ce modèle physique simplifié.




FIGURE 1 – Modèle physique simplifié menant à la métrique de Matsumoto.

En projetant les forces sur la direction du déplacement, on obtient

$$m\dot{v} = F_{\text{mot}} - mg \cos(\theta) - kv,$$

où θ est l'angle entre la direction du déplacement et la verticale ascendante. La vitesse limite est alors :

$$v = \frac{F_{\text{mot}}}{k} \left(1 - \frac{mg}{F_{\text{mot}}} \cos(\theta) \right).$$

En posant

$$v_0 = \frac{F_{\text{mot}}}{k}, \quad \|\omega\| = \frac{mg}{F_{\text{mot}}},$$

la vitesse effective devient

$$v = v_0(1 - \|\omega\| \cos(\theta)).$$

Si u représente le déplacement normalisé par la vitesse horizontale v_0 , alors $\|u\|$ est le temps de trajet sans effet de gravité. Le temps de trajet avec gravité devient donc

$$F_M(u) = \frac{\|u\|}{1 - \|\omega\| \cos(\theta)} = \frac{\|u\|^2}{\|u\| - \omega^T u}.$$

On retrouve ainsi la métrique de Matsumoto canonique.

Le frottement linéaire sert ici surtout à obtenir une vitesse limite, et donc une fonction positivement homogène de degré 1 en u . Sans ce frottement, on obtiendrait une expression proche de Matsumoto, avec la même dépendance en $\|\omega\| \cos(\theta)$ mais positivement homogène de degré 1/2 plutôt que de degré 1, c'est-à-dire proportionnelle à $\sqrt{\|u\|}$, ce qui ne définirait pas une métrique correcte. Cela montre que le facteur dépendant de la pente est naturel.

Cette interprétation doit cependant rester comprise comme un modèle simplifié. Une force motrice constante correspond davantage à un véhicule idéalisé qu'à une marche humaine. Le frottement linéaire est aussi plus naturel dans un milieu visqueux ou à très basse vitesse que pour un contact avec l'air ou le sol. Enfin, le modèle ne prend pas en compte de limite de glissement ni de coefficient de frottement dépendant de l'inclinaison.

Il existe des modèles plus proches de la marche humaine, notamment la fonction de marche de Tobler [Tobler, 1993] et le modèle énergétique de Minetti [Minetti et al., 2002]. Nous les détaillons en annexe A mais la figure 2 en donne un aperçu. Ces modèles reproduisent mieux certaines contraintes réelles, en particulier le fait que les descentes très fortes deviennent coûteuses et que certaines pentes puissent être impraticables. Cependant, ces propriétés ne sont pas nécessairement adaptées à notre cadre. L'espace d'arrivée est un embedding abstrait, pas une surface topographique réelle. De plus, leurs expressions sont plus complexes, moins régulières, et conduisent à des directions interdites ou très fortement pénalisées, ce qui peut rendre l'optimisation plus délicate.




FIGURE 2 – Comparaison qualitative de disques unité associés à Randers, Matsumoto, Tobler et Minetti. Randers et Matsumoto sont représentés avec $|\omega| = 0.4$. Tobler et Minetti reproduisent mieux certaines contraintes de la marche, mais introduisent des formes plus complexes et des directions interdites.

En conclusion, Matsumoto ne doit pas être vu comme une modélisation complète de la marche humaine, mais comme une approximation simple d'un temps de déplacement sur une pente, qui apporte donc une interprétation différente de Randers. Si Matsumoto est moins réaliste que Tobler ou Minetti, elle reste plus simple et plus directement exploitable dans un algorithme de manifold learning. Les deux sous-sections suivantes montreront que Matsumoto conserve bien plusieurs propriétés qualitatives intéressantes des déplacements sur pente, qui en font une métrique géométriquement plus riche que Randers dans ce cadre.

3.3 Géodésiques de Matsumoto

Nous nous intéressons maintenant aux propriétés géométriques de Matsumoto, en particulier à ses géodésiques. On rappelle qu'une géodésique désigne ici un chemin de plus courte longueur entre deux points, parmi les chemins restant à l'intérieur de la variété considérée, et la distance géodésique est justement la longueur de la géodésique. L'objectif est de comprendre comment la non-linéarité de Matsumoto affecte la géométrie de la variété par rapport à Randers.

Dans le cas canonique uniforme, la métrique de Randers s'écrit

$$F_R(u) = \|u\| + \omega^T u.$$

Pour un chemin γ allant de p à q , sa longueur de Randers vaut donc

$$L_R(\gamma) = \int_0^1 (\|\dot{\gamma}(t)\| + \omega^T \dot{\gamma}(t)) dt = \int_0^1 \|\dot{\gamma}(t)\| dt + \omega^T (\gamma(1) - \gamma(0)).$$

Le second terme vaut simplement $\omega^T(q - p)$, et ne dépend donc pas du chemin, seulement de ses extrémités. Trouver le chemin de longueur minimale selon Randers uniforme ou selon la métrique riemannienne (ici $M = I$ donc on est même dans le cas euclidien) est donc la même chose. Plus généralement, un raisonnement similaire vaut lorsque le terme linéaire est donné par une forme fermée, au moins localement ou dans un domaine simplement connexe. Une métrique de Randers uniforme peut donc modifier les distances orientées, mais pas les chemins minimisants par rapport à la métrique riemannienne de référence. Cette propriété n'est plus vraie en général lorsque ω dépend de la position.

La situation est différente pour Matsumoto. Même dans le cas uniforme, Matsumoto ne s'écrit pas comme une longueur riemannienne plus un terme dépendant seulement des extrémités. Sa dépendance à la direction est non linéaire :

$$F_M(u) = \frac{\|u\|}{1 - \omega^T u / \|u\|}.$$

Donc même dans notre cas canonique, le chemin optimal selon Matsumoto n'est pas nécessairement la géodésique euclidienne. La figure 3 illustre ce phénomène sur une variété simple : une surface en forme de bosse gaussienne. Le chemin le plus court entre les extrémités au sens euclidien - et donc aussi selon Randers - est celui traversant la bosse, mais Matsumoto préfère un chemin qui la contourne, où les pentes sont plus modérées.




FIGURE 3 – Exemple de chemins optimaux sur une variété en forme de bosse gaussienne. Contrairement à Randers, Matsumoto (avec $\|\omega\| = 0.49$ ici) privilégie un chemin contournant la bosse, de longueur euclidienne plus grande mais de pente plus douce.

Ce comportement peut se comprendre à partir de l'écriture de Matsumoto comme métrique de type (α, β) . Dans le cas canonique, on a

$$s(u) = \frac{\beta(u)}{\alpha(u)} = \frac{\omega^T u}{\|u\|} = \|\omega\| \cos(\theta),$$

où θ est l'angle entre u et la direction de ω . La métrique de Matsumoto s'écrit alors

$$F_M(u) = \|u\| \phi(s(u)), \quad \phi(s) = \frac{1}{1-s}.$$

Considérons maintenant un chemin γ paramétré par sa longueur euclidienne, que l'on note $\ell \in [0, L]$. On a donc $\|\gamma'(\ell)\| = 1$, et la longueur de Matsumoto devient

$$L_M(\gamma) = \int_0^L \phi(s(\gamma'(\ell))) d\ell.$$

Or

$$\phi''(s) = \frac{2}{(1-s)^3} > 0.$$

La fonction ϕ est donc convexe sur son domaine. Par l'inégalité de Jensen,

$$L_M(\gamma) = \int_0^L \phi(s(\gamma'(\ell))) d\ell \geq L \phi\left(\frac{1}{L} \int_0^L s(\gamma'(\ell)) d\ell\right).$$

À longueur euclidienne L et extrémités fixées, le terme moyen

$$\frac{1}{L} \int_0^L s(\gamma'(\ell)) d\ell$$

est fixé, car

$$\int_0^L s(\gamma'(\ell)) d\ell = \int_0^L \omega^T \gamma'(\ell) d\ell = \omega^T (\gamma(L) - \gamma(0)).$$

Le coût est donc minimal lorsque $s(\gamma'(\ell))$ est constant, c'est-à-dire lorsque le chemin garde une pente régulière. Cette propriété ne détermine pas à elle seule la géodésique complète, car un chemin plus long mais de pente plus régulière doit être comparé à un chemin plus court mais de pente plus variable. Elle montre cependant que Matsumoto privilégie les trajectoires de pentes régulières.

De plus, cette pénalisation des variations de pente est elle-même asymétrique entre montée et descente. Pour Matsumoto,

$$\phi'''(s) = \frac{6}{(1-s)^4} > 0.$$

Ainsi, ϕ'' est croissante. Pour $s > 0$, on a donc

$$\phi''(s) > \phi''(-s).$$

Une variation de pente autour d'une montée moyenne augmente donc davantage le coût qu'une variation de même amplitude autour d'une descente moyenne. Autrement dit, les irrégularités de pente sont plus pénalisées à la montée qu'à la descente.

Cette asymétrie peut modifier le chemin optimal selon le sens du déplacement. Dans l'exemple de la figure 4, deux chemins sont possibles entre les points A et B , la variété considérée étant simplement l'union des deux chemins. Le chemin Q est plus court d'un point de vue euclidien, mais présente des variations de pente extrêmes. Le chemin P est plus long mais de pente constante. Le tableau 1 montre que, pour Matsumoto avec $\|\omega\| = 0.49$, le chemin Q est le plus court à la descente alors que P est préféré à la montée.




FIGURE 4 – Exemple où le chemin optimal n'est pas le même de A à B et de B à A pour Matsumoto avec $\|\omega\| = 0.49$.

Longueur	Montée AB	Descente BA
Chemin Q	5.92	3.34
Chemin P	5.73	3.67

TABLE 1 – Longueurs des deux chemins selon le sens du déplacement, pour Matsumoto avec $\|\omega\| = 0.49$

Cette propriété d'hystérésis montre que Matsumoto uniforme peut représenter des structures de chemins plus riches que Randers uniforme. Cependant ces hystérésis ne sont pour l'instant pas très marquées. Le cas ci-dessus est volontairement favorable au phénomène : un chemin de pente constante, un avec une rupture de pente aussi marquée que possible, et un $\|\omega\|$ proche de

la limite de la convexité à $1/2$. Malgré ça, les différences de longueurs entre les deux chemins ne sont que de quelques pourcents, l'effet dans un algorithme comme Finsler-GeoMDS serait donc faible. C'est ce constat qui nous a conduit à étudier le régime non convexe de Matsumoto.

3.4 Régime non convexe

Nous nous intéressons dans cette sous-partie à la métrique de Matsumoto dans le cas $\|\omega\| > 1/2$. Ce régime entraîne une perte de convexité et sort donc du cadre Finsler régulier. Cependant, il fait apparaître des comportements géométriques potentiellement intéressants pour nos applications, ce qui motive son étude.

On note de nouveau θ l'angle entre le vecteur du déplacement u considéré et ω , c'est-à-dire l'angle avec la verticale (dans le sens ascendant). La mesure de Matsumoto augmente de plus en plus vite lorsque θ s'approche de 0, et cet effet est d'autant plus marqué que $\|\omega\|$ est grand. Pour une montée verticale, on peut donc se demander s'il n'est pas plus rapide de faire un léger détour, par exemple sous forme de zigzag, afin d'éviter une pente trop raide au prix d'une longueur euclidienne plus grande.

Cette intuition peut se formuler en regardant la vitesse verticale obtenue par unité de coût. Pour u unitaire et dans la direction θ , la vitesse de déplacement est $v(\theta) = 1 - \|\omega\| \cos(\theta)$, et la vitesse verticale vaut donc :

$$v_z(\theta) = v(\theta) \cos(\theta) = \cos(\theta) (1 - \|\omega\| \cos(\theta)).$$

On cherche alors la direction qui maximise cette progression verticale. On a

$$v'_z(\theta) = \sin(\theta) (2\|\omega\| \cos(\theta) - 1).$$

Si $\|\omega\| < 1/2$, le maximum est atteint en $\theta = 0$, donc la montée verticale est optimale. En revanche, si $\|\omega\| > 1/2$, le maximum est atteint pour

$$\theta_0 = \arccos\left(\frac{1}{2\|\omega\|}\right).$$

Dans ce régime, monter une pente très raide directement n'est donc plus optimal. Il vaut mieux, selon Matsumoto pour ce $\|\omega\|$, prendre un chemin plus long mais de pente constante θ_0 , par exemple en faisant un zigzag. Cela correspond exactement à une perte de convexité : l'inégalité triangulaire est violée, un détour par un autre point peut diminuer le coût total. La figure 5 illustre cette perte de convexité via les cercles unités. Dans le cas général, $\|\omega\|_{M^{-1}} < 1/2$ est la condition de forte convexité des métriques de Matsumoto [Shen, 2001, Chansri et al., 2020].

Sans cette convexité, Matsumoto ne définit plus une métrique de Finsler régulière. Pour $\frac{1}{2} < \|\omega\| < 1$, la fonction reste cependant positive et positivement homogène : elle peut encore être interprétée comme une fonction de coût ou de temps de trajet asymétrique. Pour $\|\omega\| > 1$,




FIGURE 5 – Cercles unité de Matsumoto pour différentes valeurs de $\|\omega\|$. Pour $\|\omega\| = 0.4$, le cercle unité reste convexe. Pour $\|\omega\| = 0.8$, la convexité est perdue et la direction optimale de montée devient $\theta_0 > 0$. Pour $\|\omega\| = 1.2$, certaines directions proches de la verticale deviennent interdites.


le dénominateur peut devenir nul ou négatif dans les directions de montée trop raide. Nous interprétons alors ces directions comme interdites, c'est-à-dire de coût infini. L'angle limite est donné par

$$\theta_{\min} = \arccos\left(\frac{1}{\|\omega\|}\right).$$


Le comportement en zigzag peut être interprété de manière assez intuitive. Si le vecteur $\overrightarrow{AB}$ forme un angle θ avec la verticale tel que $|\theta| < \theta_0$, alors le chemin direct est trop raide. Les chemins optimaux sont alors des chemins dont l'angle avec la verticale reste égal à θ_0 , par exemple un zigzag ou une spirale. Dans le sens inverse, pour une descente, le chemin direct reste optimal quand la variété l'autorise. On retrouve donc une forme d'hystérésis beaucoup plus marquée que dans le régime convexe : on ne monte pas nécessairement par le même chemin que celui que l'on prendrait pour descendre.

Ce phénomène est intéressant car il correspond à des comportements réels : pour monter une falaise, il est préférable de suivre un sentier en lacets plutôt que de l'escalader. Les modèles de marche comme Tobler ou Minetti présentent d'ailleurs un comportement similaire, si ce n'est qu'ils évitent aussi les descentes très raides. Dans notre cadre, ce régime pourrait donc fournir des visualisations et des tracés de chemins plus intuitifs.

Cependant, ces cas non convexes peuvent aussi complexifier l'optimisation dans Finsler-MDS ou GeoMDS. Le nombre de chemins optimaux peut être théoriquement infini (figure 6) et surtout dans le cas $\|\omega\| > 1$ certaines directions ont un coût infini et le gradient de F_M explose lorsque θ se rapproche de $\theta_{\min}$. Pour cette raison nous n'avons pas utilisé ce régime $\|\omega\| > 1$ en pratique dans nos expériences. On pourrait aussi noter que, si les propriétés du régime non convexe sont intéressantes pour GeoMDS, le manque de convexité pourrait rendre les visualisations du Finsler-MDS avec distances directes moins intuitives, par exemple car l'interprétation habituelle de la distance directe comme la distance géodésique si la variété considérée est l'espace tout



(a) Exemple de montée où le chemin optimal évite une direction verticale trop coûteuse. $\|\omega\| = 0.99$ ici.



(b) La variété est ici le plan entier et $\|\omega\| = 0.87$. Il y a une infinité de zigzag gardant la même pente, ils sont tous optimaux.

FIGURE 6 – Exemples de comportements géodésiques dans le régime non convexe de Matsumoto.

entier n'est plus valide.

Il reste possible de remplacer Matsumoto par une version convexifiée F_{MC} , définie $F_{MC}(u) = d_F^{\text{geo}}(0, u)$ où d_F^{geo} est calculée en autorisant les chemins dans l'espace entier. Cette construction correspond à remplacer la boule unité non convexe de Matsumoto par son enveloppe convexe, puis à considérer la jauge de Minkowski associée [Aravkin et al., 2018]. Pour Finsler-MDS direct le résultat pourrait être plus naturel visuellement. Pour GeoMDS l'effet serait moins spectaculaire et servirait surtout à permettre l'utilisation de $\|\omega\| > 1$, en effet cela revient essentiellement à supprimer un artefact de discrétisation de la variété, en autorisant les petits zigzags qui seraient disponibles dans une approximation continue. Nous n'avons pour l'instant que peu exploré cette version convexifiée dans nos tests.

3.5 Synthèse

Cette section montre que la métrique de Matsumoto, même dans le cas canonique uniforme utilisé dans ce rapport, induit une géométrie plus riche que la métrique de Randers uniforme. Ceci se manifeste surtout dans les chemins géodésiques, l'aversion de Matsumoto pour les pentes extrêmes permettant des géodésiques différentes du cas riemannien, tout en correspondant à l'intuition de marche sur une montagne.

Le régime non convexe amplifie fortement ces comportements. Bien qu'il sorte du cadre des métriques de Finsler régulières, il conserve une interprétation naturelle comme fonction de coût asymétrique et fait apparaître des phénomènes supplémentaires comme les montées en lacets ou les directions interdites. Ces propriétés pourraient rendre les embeddings obtenus avec GeoMDS plus interprétables visuellement, en particulier lorsque l'on s'intéresse aux chemins plutôt qu'aux

seules distances.

En pratique, le cas $\|\omega\| > 1$ semble trop dégénéré pour être utilisé directement dans nos algorithmes, à cause des directions interdites et des gradients très grands près de leur frontière. En revanche, le régime $1/2 < \|\omega\| < 1$, ainsi que les versions convexifiées de Matsumoto, semblent être des pistes plus prometteuses pour les applications étudiées dans ce rapport.

Cette étude théorique de Matsumoto terminée, nous nous intéressons maintenant aux implémentations algorithmiques qui nous permettront de mettre en œuvre nos extensions.

4 Optimisation algorithmique

Cette section présente les choix algorithmiques utilisés pour implémenter Finsler-MDS et ses extensions. Nous commençons par revenir sur le cas des distances directes, correspondant au cadre de Finsler-MDS standard, pour discuter de l'utilisation de la simple descente de gradient par rapport à Finsler-SMACOF, notamment pour le cas de Matsumoto. Nous en profitons aussi pour corriger un problème de majoration que nous avons remarquée dans Finsler-SMACOF.

L'essentiel de cette section est ensuite consacré à l'extension géodésique GeoMDS, qui présente un problème algorithmique plus délicat. Celle-ci doit optimiser sur les distances géodésiques le long de la variété formée par les points, ce qui rend le problème non lisse et demande d'effectuer des parcours de graphe coûteux. Nous présentons donc les approches testées pour rendre cet objectif exploitable en pratique : l'algorithme *Path-Frozen Alternating Optimization*, des relaxations différentiables de type soft-Bellman-Ford ou soft-Floyd-Warshall, puis plusieurs heuristiques de passage à l'échelle.

4.1 Distances directes : SMACOF et descente de gradient

Commençons par le cadre d'origine de Finsler-MDS, où les distances utilisées dans l'espace d'arrivée sont les distances directes. Il s'agit donc de trouver les coordonnées $Y = (y_i)$ minimisant le stress

$$\sigma_F(Y) = \sum_{i \neq j} w_{ij} (F(y_j - y_i) - D_{ij})^2.$$

Dans le cas de Randers canonique, Dagès et al. [2025b] proposent d'utiliser Finsler-SMACOF, une adaptation de l'algorithme SMACOF utilisé dans le MDS standard. Le principe de SMACOF est de majorer itérativement le stress par une fonction quadratique plus simple à minimiser. Une alternative plus directe est d'effectuer une descente de gradient sur le stress. Nous revenons ici sur ces deux approches, car elles déterminent aussi le choix d'optimisation retenu pour notre extension à la métrique de Matsumoto.

Nous avons cependant identifié une inexactitude dans le Finsler-SMACOF proposé¹. Dans Finsler-SMACOF comme dans SMACOF classique, l'un des termes du stress est majoré par

1. L'erreur se trouve dans l'expression de $B_{ij}(X)$, page 5, colonne gauche, dans la version consultée de l'article.

l'inégalité de Cauchy-Schwarz :

$$\|x_j - x_i\| \geq \frac{\langle x_j - x_i, z_j - z_i \rangle}{\|z_j - z_i\|},$$

où $Z = (z_i)$ est l'itéré courant. Cette inégalité impose un dénominateur euclidien $\|z_j - z_i\|$. Dans l'expression publiée de Finsler-SMACOF, les termes de la matrice $B(X)$ qui sont construits à partir de cette inégalité remplacent au dénominateur la norme par la distance de Randers, ce qui ne donne plus une majoration valide du stress. En effet la distance de Randers peut être inférieure à la norme euclidienne dans certaines directions, et le membre de droite peut alors devenir trop grand. L'itération obtenue n'est donc plus garantie monotone. La correction consiste simplement à remplacer ce dénominateur par la norme euclidienne.

Nous avons aussi identifié deux incohérences dans l'implémentation publique fournie par les auteurs : un coefficient $\alpha = \|\omega\|$, qui devrait apparaître sous la forme α^2 , et une symétrisation manquante de la contribution en D dans l'update matricielle.

La figure 7 illustre l'effet de cette correction. L'ancien Finsler-SMACOF peut augmenter le stress après quelques itérations, ce qui conduit à un arrêt précoce, même si le stress peut ensuite diminuer à nouveau. Mais que l'on active l'arrêt précoce ou non, l'embedding obtenu est moins visuellement cohérent et à un moins bon stress final que ce qu'on obtient en utilisant notre version corrigée ou une descente de gradient, ces deux méthodes donnant des résultats très proches.




FIGURE 7 – Comparaison entre descente de gradient, Finsler-SMACOF corrigé et ancienne version de Finsler-SMACOF sur un exemple d'embedding du dataset Pancreas. L'ancienne version peut augmenter le stress, ce qui explique son arrêt précoce.

Méthode	Nombre d'itérations	Stress final
Descente de gradient	100	4.82×10^8
Ancien Finsler-SMACOF, arrêt précoce	21	2.43×10^9
Ancien Finsler-SMACOF	300	2.37×10^9
Finsler-SMACOF corrigé	300	4.83×10^8

TABLE 2 – Stress final obtenu par les différentes variantes d'optimisation représentées dans la figure 7.

Mentionnons aussi les temps de calcul de Finsler-SMACOF (corrigé) par rapport à une descente de gradient, pour obtenir un stress similaire (moins de 1% de différence). Ces résultats sont surtout indicatifs et servent à donner un ordre de grandeur. Sur le dataset Pancreas, contenant 2531 cellules, les deux algorithmes donnent des temps comparables dans le cas de poids w_{ij} uniformes, avec environ 5 secondes pour la descente de gradient contre environ 6 pour SMACOF. Ce cas de poids uniformes simplifie l'expression des calculs et l'implémentation publique en prend avantage. En revanche, dans le cas de poids non uniformes, SMACOF devient nettement moins compétitif, avec un temps d'environ 130 secondes contre toujours 5 secondes pour la descente de gradient. Ces valeurs dépendent de l'implémentation et des paramètres, mais elles montrent que SMACOF n'apporte pas ici d'avantage pratique systématique.

Cela est important pour l'extension à Matsumoto. La majoration de Finsler-SMACOF repose fortement sur la structure particulière de Randers :

$$F_R(u) = \|u\| + \omega^T u.$$

Comme la dépendance en $\omega^T u$ est affine, le stress peut être séparé en une partie euclidienne, traitée comme dans SMACOF classique, et des termes linéaires ou quadratiques simples. Cette simplification ne se retrouve pas pour Matsumoto :

$$F_M(u) = \frac{\|u\|^2}{\|u\| - \omega^T u}.$$

La dépendance en $\omega^T u$ y est non linéaire, et nous n'avons pas trouvé de majorant quadratique suffisamment simple à optimiser pour obtenir un équivalent utile de SMACOF. À l'inverse, la descente de gradient s'adapte directement à Matsumoto : tant que l'on reste dans le régime $\|\omega\| < 1$, ou que l'on utilise une version convexifiée lorsque nécessaire, le calcul du gradient ne présente pas de difficulté particulière. C'est donc cette approche que nous utiliserons pour Finsler-MDS avec Matsumoto, et elle servira aussi de base aux optimisations géodésiques présentées dans les sous-sections suivantes.

4.2 Path-Frozen Alternating Optimization

Nous abordons maintenant le cas de notre extension GeoMDS, où nous remplaçons dans l'expression du stress la distance directe entre les points de l'embedding Y par la distance géodésique le long de la variété où vit Y . Cette variété est approximée par un graphe $G(Y)$ de voisinage kNN dont les arêtes sont pondérées par la métrique choisie et les distances géodésiques sont alors les longueurs des plus courts chemins dans ce graphe. Ceci nous fait bien sûr sortir du cadre de SMACOF, même dans le cas euclidien ou Randers, et même une descente de gradient sur le stress est en pratique difficile. En effet déplacer les points de Y modifie les poids des arêtes de $G(Y)$ et peut changer les k-voisinages des points, c'est-à-dire faire apparaître et disparaître des arêtes dans $G(Y)$. Tout cela modifie les plus courts chemins entre points, ce qui fait que les distances géodésiques varient de façon non lisse, voire non-continue.

Une approche naturelle pour résoudre ce problème est celle de l'algorithme *Path-Frozen Alternating Optimization* 1 que nous proposons. Nous l'appellerons simplement *Path-Frozen* dans la suite. Son principe est qu'en dehors des instants où un chemin optimal change - à cause d'un changement de voisin kNN ou juste à cause des changements de poids des arêtes - les distances géodésiques s'expriment comme les sommes des longueurs des arêtes du chemin optimal, le gradient du stress peut donc être obtenu en différentiant les longueurs de ces arêtes. Notre algorithme Path-Frozen consiste donc à calculer les chemins optimaux actuels, effectuer quelques pas de descente de gradient sur le stress en supposant que les chemins calculés restent les chemins optimaux - en "gelant" les chemins donc - puis actualiser le graphe kNN, calculer les nouveaux chemins optimaux, faire une descente de gradient sur ces chemins gelés, et ainsi de suite. Le calcul des chemins optimaux est fait en utilisant l'algorithme de Dijkstra depuis chaque point. Dans notre cas d'un graphe sparse kNN, Dijkstra depuis chaque source est généralement considéré comme l'algorithme de distances all-to-all le plus efficace, avec une complexité en $O(kn^2 \log n)$.

Algorithme 1 : Path-Frozen Alternating Optimization

Input : Dissimilarités cibles D , poids w , initialisation $Y^{(0)}$, nombre d'itérations externes N_{outer} , nombre d'itérations internes N_{inner}

Output : Embedding optimisé Y

$Y \leftarrow Y^{(0)}$; **for** $t = 1, \dots, N_{outer}$ **do**

 Construire le graphe de voisinage $G(Y)$ à partir de l'embedding courant;

 Pondérer chaque arête (a, b) par la distance $F(y_b - y_a)$;

 Calculer les plus courts chemins actuels π_{ij} sur $G(Y)$;

 Définir la distance sur chemins gelés

$$\tilde{d}_{ij}(Y) = \sum_{(a,b) \in \pi_{ij}} F(y_b - y_a);$$

 Calculer le stress correspondant

$$\tilde{\sigma}(Y) = \sum_{i \neq j} w_{ij} \left(\tilde{d}_{ij}(Y) - D_{ij} \right)^2;$$

 Mettre à jour Y par N_{inner} étapes de descente de gradient sur $\tilde{\sigma}(Y)$;

return Y ;

On peut distinguer ici le nombre N_{outer} d'itérations externes où on recalcule les chemins optimaux et lance la descente de gradient, et le nombre N_{inner} d'itérations de cette descente de gradient à chaque itération externe. Il est possible que les chemins gelés ne soient plus les plus courts après quelques itérations internes et que le reste de la descente de gradient n'optimise donc plus le bon objectif. Utiliser un N_{inner} faible permet de limiter cet effet, mais en contrepartie le nombre d'utilisations de Dijkstra augmentera pour un même nombre de pas de descente de gradient, ce qui représente un coût computationnel conséquent. Il y a donc un compromis à trouver, qui dépend de la complexité de la géométrie que l'on essaie de reconstruire et de la qualité de l'initialisation, entre autres. Une stratégie efficace est de choisir un N_{inner} plus grand en début d'optimisation pour accélérer la phase où la géométrie globale est construite, puis de

le réduire en fin d’optimisation pour plus de précision. Pour donner un ordre de grandeur, nous faisons au plus varier N_{inner} de 1 à 50 dans nos tests. Par ailleurs nous utilisons aussi pour réduire la sur-optimisation un paramètre de relaxation $s \in [0, 1]$ entre deux itérations externes : au lieu de remplacer directement Y_{old} par Y_{new} , nous le remplaçons par $(1 - s) \cdot Y_{old} + s \cdot Y_{new}$.

4.3 Approches différentiables

Si Path-Frozen accepte le caractère non lisse du problème, une autre approche consiste à le lisser en rendant le calcul de plus court chemin différentiable. Comme nous l’avons mentionné dans l’état de l’art, cela peut être fait en remplaçant dans un algorithme de calcul de distance sur graphe les opérations de minimum par des soft-minimums, définis par :

$$\text{softmin}_\beta(a_1, \dots, a_m) = -\frac{1}{\beta} \log \left(\sum_{r=1}^m e^{-\beta a_r} \right),$$

qui tend vers le minimum lorsque $\beta \rightarrow +\infty$. Cette relaxation permet de propager un gradient à travers le choix du chemin optimal, au lieu d’avoir à considérer un chemin fixé.

Nous nous sommes intéressés à deux approches de ce type. La première est l’algorithme DataSP [Lahoud et al., 2024], qui est une variante différentiable de l’algorithme de Floyd-Warshall. Floyd-Warshall calcule les distances des plus courts chemins entre toutes les paires de sommets - ou une approximation différentiable pour DataSP - via une récurrence dynamique sur les sommets intermédiaires. Son inconvénient est sa complexité en $O(n^3)$, indépendamment du fait que notre graphe kNN soit sparse. Cela le rend rapidement trop coûteux pour nos expériences.

La seconde approche est une version différentiable de l’algorithme de Bellman-Ford, proche des formulations parfois appelées *soft Bellman-Ford* [François et al., 2017]. Bellman-Ford calcule les distances depuis une source en répétant des relaxations d’arêtes. Dans notre cas, on peut remplacer chaque relaxation par une relaxation soft, puis appliquer l’algorithme depuis plusieurs sources. Si l’on note m le nombre d’arêtes du graphe et R le nombre de relaxations (longueur maximale des chemins testés), le coût est de l’ordre de $O(Rm)$ pour une source, donc $O(Rnm)$ pour toutes les sources. Pour un graphe kNN, on a $m \simeq kn$, ce qui donne un coût de l’ordre de $O(Rkn^2)$. Il s’agit donc d’un algorithme profitant de la structure sparse d’un graphe kNN. Choisir R trop faible empêche de tester tous les chemins, ce qui peut donner une expression faussée de la distance géodésique différentiable (elle peut même être infinie si R est inférieur au diamètre du graphe) mais plus R est grand, plus l’algorithme est lent.

Ces méthodes règlent une partie du problème de Path-Frozen. Sur un graphe fixé, le fait que le chemin optimal change est donc pris en compte par la manière dont le soft-minimum combine les contributions des différents chemins. En revanche, elles ne prennent pas en compte le fait que le graphe lui-même change à cause des changements de k-voisinage. Nos implémentations gardent donc la structure de Path-Frozen, avec plusieurs itérations externes où le graphe est recalculé et l’algorithme de calcul des distances est utilisé à nouveau. On peut cependant espérer avoir besoin de faire ce recalcul moins souvent que dans Path-Frozen puisque les changements

de chemin optimal sont lissés.

L'effet des changements de k -voisinage pourrait lui aussi être lissé, par exemple avec des opérateurs de type SOFT top- k [Xie et al., 2020]. Mais cela impose en pratique de considérer un graphe dense ou quasi dense, où les arêtes qui ne sont pas dans les k plus proches voisins reçoivent seulement un poids très défavorable au lieu de disparaître. Pour nos objectifs, cela augmenterait fortement le coût des algorithmes de plus courts chemins. Il est donc plus raisonnable de conserver une reconstruction explicite du graphe, comme dans Path-Frozen.

Mentionnons enfin que le soft-minimum introduit aussi un biais entropique. Si M chemins ont exactement la même longueur L , alors leur soft-minimum vaut

$$-\frac{1}{\beta} \log \left(M e^{-\beta L} \right) = L - \frac{\log M}{\beta}.$$

La distance relaxée est donc plus petite que la distance réelle lorsqu'il existe beaucoup de chemins presque optimaux. Ce phénomène peut être problématique dans le régime non convexe de Matsumoto, où des montées en zigzag peuvent produire un grand nombre de chemins de longueurs très proches. La relaxation soft induit donc un biais qui changera légèrement l'embedding final.

En pratique, soft-Bellman-Ford s'est révélé plus exploitable que soft-Floyd-Warshall, car il peut profiter du caractère sparse du graphe kNN. Il reste cependant plus coûteux et plus difficile à régler que Path-Frozen, principalement parce qu'il n'élimine pas la nécessité de recalculer le graphe, et que Dijkstra est plus rapide que Bellman-Ford. Par ailleurs, utiliser une version différentiable de Dijkstra serait bien plus compliqué, car cet algorithme est fondé sur une sélection gloutonne de sommets via une file de priorité, pas une récurrence où on peut simplement changer les minimums en soft-minimums. Les heuristiques de passage à l'échelle présentées dans la sous-section suivante seront donc surtout discutées pour Path-Frozen, et dans une moindre mesure pour soft-Bellman-Ford.

4.4 Heuristiques de passage à l'échelle

Path-Frozen - et a fortiori les approches différentiables ci-dessus - restent coûteux. Chaque itération externe demande d'effectuer Dijkstra depuis chaque sommet, de garder en mémoire les chemins optimaux entre toutes les paires et d'effectuer plusieurs pas de descente de gradient sur le stress gelé, dont l'expression et donc le gradient sont plus complexes que dans le MDS classique. Ceci rend l'algorithme difficilement utilisable en l'état dès que le jeu de données dépasse les 1000 points. Nous avons donc développé certaines heuristiques pour accélérer la vitesse d'exécution de Path-Frozen tout en dégradant le moins possible son efficacité. Ces heuristiques s'adaptent aussi à Soft Bellman-Ford, qui fonctionne également par source, mais pas à DataSP.

Notre première heuristique, inspirée de la façon dont Landmark-MDS [de Silva and Tenenbaum, 2004] calcule ses dissimilarités géodésiques, est de n'effectuer Dijkstra que depuis certains points,

appelés *landmarks*, et de ne considérer dans le stress pour la descente de gradient uniquement les paires (i, j) où i est un landmark. L'intuition est qu'optimiser le stress sur toutes les paires de points utilise beaucoup d'information redondante : si i et i' sont proches l'un de l'autre mais loin de j , alors les dissimilarités D_{ij} et $D_{i'j}$ tout comme les chemins optimaux de i et i' vers j seront semblables, donc ne pas considérer la paire (i', j) n'est pas une grande perte d'information.

Selon la même logique, on peut aussi limiter pour chaque landmark i le nombre de cibles (*targets*) j tels que la paire (i, j) soit considérée pour la descente de gradient. Ceci ne réduit pas le nombre d'utilisations de Dijkstra - il y en a toujours une par landmark - mais réduit le nombre de chemins à garder en mémoire et le nombre de termes du stress pour la descente de gradient.

Dans notre implémentation, les landmarks sont choisis une fois pour toutes en début d'optimisation, soit par farthest-point sampling soit aléatoirement. Les re-sélectionner à chaque itération externe dans le cas aléatoire est tout à fait envisageable mais nous ne le faisons pas pour l'instant, d'une part pour pouvoir comparer directement à la méthode farthest-point sampling, d'autre part car fixer les landmarks permet de calculer à chaque itération externe un stress partiel qui reste cohérent sans grand coût de calcul supplémentaire. Les targets, eux, sont re-sélectionnés aléatoirement pour chaque landmark à chaque itération externe. Nous avons choisi ce comportement pour pouvoir couvrir l'ensemble du jeu de données au cours de l'optimisation, apportant de la régularisation pour compenser le choix définitif des landmarks. Si landmarks et targets étaient choisis par farthest point sampling, des régions intermédiaires pourraient être complètement délaissées.

Il faut cependant noter que ce système de landmarks et targets, s'il parvient à capturer la géométrie globale, n'est pas suffisant pour conserver avec précision la géométrie locale. Nous voudrions donc ajouter toutes les paires de voisins (au sens des dissimilarités : les points qui doivent être proches) aux calculs de la descente de gradient, en plus des paires landmark-target. Le faire normalement impliquerait d'effectuer Dijkstra depuis tous les points, ce qui enlève l'intérêt de l'heuristique des landmarks (sauf si la descente de gradient est le bottleneck, mais ce n'est pas souvent le cas). L'alternative que nous avons implémentée est d'approximer la distance géodésique entre les voisins par leur distance directe. En effet même si ces points peuvent n'être voisins que selon les dissimilarités et pas dans l'embedding, le but est qu'ils le deviennent et utiliser ainsi la distance directe les pousse vers le bon objectif. Par ailleurs nous pouvons régler les poids des paires pour régler l'importance relative des paires locales (entre voisins) et globales (landmark-target).

L'annexe B présente nos mesures d'évolution du stress total au cours du temps pour différentes heuristiques sur des jeux de données synthétiques. Elles montrent que la stratégie de landmarks/targets seule peut s'avérer moins efficace que de considérer toutes les paires dans certains cas, bien que dans d'autres elle soit plus efficace. Par contre lorsqu'on la combine à l'utilisation des paires locales avec distance directe, le stress diminue systématiquement plus vite et vers une limite aussi basse. Nos autres tests sur ces mêmes jeux de données confirment que Soft

Bellman-Ford, même en utilisant les mêmes heuristiques, est plus lent que Path-Frozen.

En conclusion, l'algorithme Path-Frozen que nous proposons, accompagné des heuristiques de landmarks, targets et paires locales directes, constitue dans nos tests l'approche la plus efficace pour implémenter GeoMDS. Soft-Bellman-Ford reprend une partie des mêmes heuristiques et reste une alternative pertinente, mais il est plus coûteux et plus sensible au choix de ses paramètres. DataSP/soft-Floyd-Warshall est encore plus difficile à utiliser à cette échelle. GeoMDS reste pour l'instant plus lent que les versions de MDS ou Finsler-MDS avec distances directes, mais Path-Frozen rend son optimisation praticable sur les jeux de données considérés dans ce rapport.

Ces choix algorithmiques définissent les méthodes qui seront utilisées dans les expériences. La section suivante évalue leur comportement sur des jeux de données synthétiques contrôlés, puis sur des données réelles de biologie unicellulaire.

5 Expériences et résultats

Cette section présente les évaluations expérimentales réalisées à ce stade du stage. Certaines expériences restent à consolider, en particulier sur les données biologiques, et le mois de stage restant y sera en partie dédié.

Nous présentons d'abord des cas synthétiques simples, servant à vérifier les avantages que l'extension géodésique ou l'usage de Matsumoto peuvent apporter. Nous nous pencherons ensuite sur deux applications à des données biologiques. Ces expériences ont pour but de montrer que nos méthodes peuvent être appliquées à des jeux de données réels, et d'évaluer si elles apportent un bénéfice dans ces contextes. Elles ont aussi servi à établir des baselines pour Finsler-MDS sur données réelles, auxquelles nous pourrions comparer nos extensions, l'article d'origine de Finsler-MDS se concentrant surtout sur des cas contrôlés.

5.1 Données synthétiques

Commençons par les tests réalisés sur des jeux de données synthétiques. Ils servent à vérifier, dans des cas contrôlés, que l'usage de distances géodésiques dans l'espace d'arrivée peut apporter un avantage par rapport aux distances directes. Nous en présentons deux exemples. La comparaison entre Randers et Matsumoto dans GeoMDS reste en revanche moins avancée : les propriétés géodésiques de Matsumoto mises en évidence en section 3 apparaissent bien dans certains cas contrôlés, mais nous n'avons pas encore obtenu de jeu de dissimilarités où elles produisent une amélioration visuelle et quantitative nette par rapport à Randers.

Le premier exemple, que nous appelons *Nested*, présente un cas où les distances géodésiques ne peuvent pas être correctement représentées par des distances directes. Le jeu de données est constitué de deux rectangles imbriqués en 3D, formant un angle de 90° et reliés en leur centre par une barre. Les dissimilarités cibles sont des distances géodésiques calculées comme dans Isomap. Nous nous intéressons aux embeddings en 2D que MDS et GeoMDS peuvent donner.




FIGURE 8 – Dataset synthétique Nested et ses embeddings.

Il existe une projection qui conserve presque parfaitement les distances géodésiques : il suffit d’imbriquer les rectangles. Ceci correspond au minimum global pour GeoMDS, qui est en effet dans nos tests un point de stabilité de Path-Frozen (même s’il n’y converge qu’avec une bonne initialisation), qui donne un stress minuscule de 2×10^{-6} . En revanche pour MDS, que nous utilisons SMACOF ou une descente de gradient et que l’initialisation soit une ACP (qui donne une vue de face, écrasant le petit rectangle) ou le résultat optimal de GeoMDS, le résultat minimisant les distances directes ne reflète que très mal la géométrie d’origine. La figure 8 présente les données Nested et les embeddings obtenus. Notons que des critères de type wormhole peuvent aussi limiter certaines déformations de MDS dues aux trous en retirant du stress des paires problématiques [Bracha et al., 2024] ; GeoMDS adopte une approche différente qui ne repose que sur la modification de la distance d’arrivée.

Le second jeu de données synthétique, appelé Converging Flow, consiste en un rectangle aligné selon y avec une barre en son centre $y = 0$, et soumis à un courant allant vers $y = 0$. Le courant est donc vers le bas sur la partie haute, et vers le haut sur la partie basse. Les dissimilarités sont ici des distances géodésiques selon une métrique de Randers non uniforme - en prenant comme ω l’opposé du vecteur courant en chaque point - et sont donc asymétriques. On utilise Finsler-MDS et GeoMDS avec la métrique de Randers (uniforme) pour faire une projection en 3D. On prend à chaque fois $\|\omega\| = 0.5$.




FIGURE 9 – Dataset synthétique Converging Flow et ses embeddings

Les deux embeddings prennent une forme en V, afin que la métrique de Randers uniforme de l'espace d'arrivée reproduise le courant non uniforme des données. Cependant l'usage des distances directes dans Finsler-MDS gêne ici : il veut éloigner les parties qui ont une distance géodésique forte, ce qui peut se voir dans la forme arrondie des rectangles, et aussi par le fait que le V est plus aplati que dans GeoMDS. Il y a un compromis entre éloigner les deux branches et respecter l'asymétrie. Pour une vérification quantitative, le stress des optimiseurs est intéressant mais pas directement comparable, intéressons-nous donc plutôt aux asymétries relatives :

$$A_{ij} = \frac{d_{ij} - d_{ji}}{d_{ij} + d_{ji}}$$

où d_{ij} sont les dissimilarités si on s'intéresse aux données d'origine A_{ij}^{data} ou les distances utilisées dans l'optimisation pour A_{ij}^{emb} , directes pour Finsler-MDS et géodésiques pour GeoMDS. On s'intéressera pour chacun des deux embeddings à la pente de la régression linéaire de A_{ij}^{emb} pour A_{ij}^{data} et à la RMSE (racine de l'erreur quadratique moyenne) de cette régression linéaire. Les résultats sont dans le tableau 3.

Méthode	Stress final	Pente de régression	RMSE
Finsler-GeoMDS (Path-Frozen)	1.16	0.996	0.007
Finsler-MDS (Finsler-SMACOF)	4355.9	0.618	0.126

TABLE 3 – Comparaison quantitative de la préservation des asymétries relatives sur Converging Flow

On a bien une pente de régression plus faible pour Finsler-MDS (0.618) alors que Finsler-GeoMDS a réussi à conserver presque exactement l'amplitude des asymétries (pente de 0.996). La différence de RMSE montre que même en-dehors de ce problème d'amplitude, Finsler-GeoMDS a mieux préservé les asymétries.

5.2 Inférence de trajectoire : Paul15

Comme mentionné dans l'état de l'art, le premier domaine d'application envisagé est l'inférence de trajectoire. Dans ce contexte, on cherche à organiser des cellules selon une progression biologique, souvent résumée par un pseudotime. L'importance des trajectoires dans ce domaine, ainsi que le fait que certaines méthodes comme Monocle 3 [Trapnell et al., 2014, Cao et al., 2019] fassent intervenir des distances de chemin sur un graphe principal construit dans un embedding 2D, en font un choix naturel pour tester GeoMDS.

Nos tests sur ce domaine restent cependant à un stade préliminaire. Nous avons utilisé le jeu de données Paul15 [Paul et al., 2015], très répandu dans le domaine et relativement petit, avec 2700 cellules. Il ne dispose cependant pas de ground-truth connu pour nous permettre de mesurer la cohérence que pourrait apporter GeoMDS entre les distances dans l'embedding et le pseudotime. Dans la suite du stage, nous souhaitons donc tester ces méthodes sur un jeu de données disposant d'un pseudotime ou d'annotations temporelles plus explicites.




FIGURE 10 – Visualisations de Paul15 dans le pipeline de la méthode PAGA. Les couleurs correspondent au pseudotime calculé par PAGA sur les deux transformations cellulaires principales.

La figure 10 présente des visualisations obtenues avec MDS ou GeoMDS. En l’absence de métrique d’évaluation fiable à ce stade, cette expérience ne constitue pas une validation quantitative de GeoMDS ; elle doit plutôt être comprise comme une vérification qualitative de l’applicabilité de la méthode à un pipeline d’inférence de trajectoire.

5.3 RNA-velocity : Pancreas

L’autre domaine de biologie unicellulaire qui nous a intéressé est la RNA-velocity, où l’on dispose pour chaque cellule d’un vecteur estimant sa direction locale d’évolution. En interprétant cette information comme un effet de courant, on peut construire des dissimilarités asymétriques et appliquer Finsler-MDS pour obtenir des embeddings qui respectent mieux l’alignement entre les vecteurs de vitesse et les directions vers les cellules voisines.

Nous avons utilisé le jeu de données Pancreas [Bastidas-Ponce et al., 2019], standard dans ce domaine, contenant 2531 cellules. Nous travaillons à partir d’une ACP de dimension 50 des données d’expression. Nous calculons nos dissimilarités asymétriques comme des distances géodésiques calculées sur un graphe avec une métrique de Randers non uniforme, correspondant à un effet de courant dans le sens des vecteurs de vitesse, ce qui se traduit par des ω de sens opposé aux vitesses en chaque point. L’intensité de cette asymétrie est réglée par un paramètre α_{vel} . Nous appliquons ensuite Finsler-MDS ou GeoMDS à ces dissimilarités, en utilisant Randers ou Matsumoto dans l’espace d’arrivée, avec un second paramètre α_{emb} contrôlant l’intensité de l’asymétrie dans l’embedding. Le cas $\alpha_{\text{vel}} = \alpha_{\text{emb}} = 0$ correspond au MDS ou GeoMDS symétrique. Les embeddings peuvent être en 2D ou en 3D, nous commencerons par présenter des cas en 2D. Nous utiliserons généralement UMAP comme initialisation de Finsler-MDS, et Finsler-MDS comme initialisation de GeoMDS.

Pour évaluer la qualité des embeddings produits, nous avons considéré trois métriques. Chacune utilise les vecteurs de vitesse projetés dans l’embedding, comme dans les pipelines usuels de RNA-velocity [Bergen et al., 2020]. L’annexe C détaille leur calcul, mais nous en donnons ici l’idée générale. La Cross-Boundary Direction correctness (CBDir) évalue si les vecteurs des points situés aux frontières entre clusters pointent vers les transitions biologiques attendues.




FIGURE 11 – Représentation UMAP du dataset Pancreas, avec vecteurs de vitesse projetés

L’In-Cluster Velocity Coherence (ICVCoh) mesure si les vecteurs de vitesse sont localement cohérents à l’intérieur des clusters. Ces deux premières métriques sont couramment utilisées en RNA-velocity pour mesurer la cohérence globale et locale des vitesses [Qiao and Huang, 2021]. Nous ajoutons également une métrique visant plus directement la préservation des directions de vitesse par rapport au placement des points : la Velocity Alignment Correlation (VAC). Il s’agit de la corrélation de Spearman [1904] entre les cosinus des angles formés par le vecteur de vitesse d’un point et les directions vers ses voisins, dans l’espace d’origine et dans l’embedding.




FIGURE 12 – Comparaison entre UMAP, MDS symétrique et Finsler-MDS avec une métrique de Randers. Les couleurs correspondent aux types cellulaires.

Nous commençons par comparer UMAP, MDS symétrique et Finsler-MDS. La figure 12 illustre le comportement général : UMAP donne une visualisation très lisible des clusters, tandis que MDS produit une structure plus étirée et moins adaptée aux transitions de vitesse. L’ajout d’une métrique de Randers permet de modifier la géométrie de l’embedding afin de mieux représenter certaines asymétries induites par la vitesse.

Le choix de α_{vel} et α_{emb} introduit un compromis. Augmenter α_{vel} donne plus d’importance aux asymétries issues des vitesses dans les dissimilarités cibles. Augmenter α_{emb} permet ensuite

à l’embedding de représenter plus fortement ces asymétries. En pratique, les métriques liées aux alignements de vélocité s’améliorent souvent lorsque l’asymétrie augmente, mais cela peut déformer les distances ou rendre l’embedding moins lisible. Les couples de paramètres présentés ci-dessous ont été choisis comme configurations représentatives de ce compromis, à partir d’une exploration empirique limitée. La figure 13 montre quelques configurations obtenues avec Randers.




FIGURE 13 – Effet des paramètres α_{vel} et α_{emb} sur Finsler-MDS avec Randers. Lorsque α_{emb} est grand devant α_{vel} , l’embedding doit s’aligner verticalement pour respecter les asymétries.

Méthode	α_{vel}	α_{emb}	CBDi	ICVCoh	VAC
UMAP 2D	—	—	0.586	0.843	0.438
MDS 2D	0	0	0.491	0.807	0.363
Randers 2D	0.5	0.6	0.536	0.810	0.430
Randers 2D	1	0.8	0.579	0.821	0.466
Matsumoto 2D	0.5	0.6	0.550	0.818	0.393
Matsumoto 2D	1	0.8	0.589	0.805	0.389
GeoMDS symétrique 2D	0	0	0.478	0.773	0.320
GeoMDS Randers 2D	1	0.8	0.448	0.783	0.372
GeoMDS Matsumoto 2D	1	0.8	0.510	0.774	0.316

TABLE 4 – Métriques d’évaluation sur le dataset Pancreas sur des embeddings 2D. Toutes les métriques sont à maximiser.

Le tableau 4 résume nos métriques pour quelques méthodes représentatives. Finsler-MDS entraîne systématiquement un gain de CBDi et de VAC par rapport au MDS standard, tandis que l’ICVCoh est légèrement meilleur. Ceci montre que l’information d’asymétrie est bien utilisée pour produire une géométrie cohérente avec les vecteurs de vélocité. UMAP, qui est

symétrique mais conserve très bien la géométrie locale, reste comparable aux meilleurs résultats de Finsler-MDS : il obtient le meilleur ICVCoh et de bons CBBDir et VAC. Toutefois, UMAP est une méthode différente des variantes de MDS et ne préserve pas, par exemple, les distances globales ; la comparaison reste donc surtout indicative. On peut observer que Matsumoto donne de meilleurs CBBDir mais Randers donne un meilleur VAC, cela montre qu'ils privilégient chacun une certaine partie de l'asymétrie, sans qu'un soit globalement meilleur.

Nous avons également testé l'extension géodésique GeoMDS avec Path-Frozen. La figure 14 compare Finsler-MDS direct et GeoMDS pour un même choix de paramètres. Contrairement aux exemples synthétiques précédents, GeoMDS semble plutôt détériorer les résultats ici. Les embeddings obtenus sont souvent moins réguliers, et les métriques sont généralement inférieures à celles de Finsler-MDS direct. Deux explications semblent probables : d'une part, la géométrie de ce dataset n'est pas nécessairement mieux représentée par des distances géodésiques dans l'espace d'arrivée ; d'autre part, Path-Frozen reste un optimiseur plus approximatif que SMACOF ou la descente de gradient sur distances directes. Le bruit introduit par les recalculs de graphe et les chemins gelés diminue la cohérence locale, tandis qu'il n'y a pas de gain substantiel au niveau de la géométrie globale.





FIGURE 14 – Comparaison entre Finsler-MDS direct et GeoMDS

Enfin, nous avons réalisé quelques tests en dimension 3. L'espace supplémentaire peut parfois faciliter le compromis entre organisation des clusters et préservation des directions de vélocité. Cependant, les résultats restent mitigés : Finsler-MDS n'arrive à battre UMAP 3D dans aucune métrique, et si le VAC est parfois meilleur qu'en 2D, l'ICVCoh descend légèrement et le CBBDir plus fortement. Les comparaisons 2D/3D doivent cependant être interprétées avec prudence, car l'ajout d'une dimension change la distribution des angles et peut réduire certains alignements, et donc nos métriques. Nos tests en 3D sont actuellement à un stade exploratoire, notamment avec GeoMDS, mais les mêmes résultats semblent s'appliquer au cas géodésique.

Une curiosité remarquée durant nos tests est qu'arrêter SMACOF ou la descente de gradient de Finsler-MDS après seulement une ou quelques itérations donne généralement de meilleurs

FIGURE 15 – Embedding 3D de Finsler-MDS Randers pour $\alpha_{\text{vel}} = 0.5$, $\alpha_{\text{emb}} = 0.2$.

Méthode	α_{vel}	α_{emb}	CBDi	ICVCoh	VAC
UMAP 3D	—	—	0.530	0.832	0.450
MDS 3D	0	0	0.408	0.797	0.398
Randers 3D	0.5	0.2	0.420	0.802	0.440
Randers 3D	1	0.8	0.466	0.787	0.421
Matsumoto 3D	0.5	0.2	0.419	0.802	0.436
Matsumoto 3D	1	0.8	0.446	0.772	0.347

TABLE 5 – Métriques d’évaluation sur des embeddings 3D de Pancreas.

résultats selon nos métriques. Augmenter le nombre d’itérations les diminue ensuite fortement, avant qu’elles remontent lorsqu’on s’approche du résultat de Finsler-MDS. Cette idée de *one-step refinement* n’a pas encore été étudiée systématiquement, mais elle pourrait constituer une piste intéressante, qui serait notamment à comparer avec des méthodes de type Finsler-UMAP.

En résumé, les expériences sur Pancreas montrent surtout que l’introduction d’asymétries dans Finsler-MDS peut apporter un gain réel sur certaines métriques liées à la RNA velocity, en particulier celles mesurant la préservation des alignements directionnels. En revanche, nos extensions n’ont pas été décisives sur ce dataset. Matsumoto donne un compromis légèrement différent de Randers, tandis que GeoMDS ne semble pas apporter de réel gain. Ces résultats confirment donc l’intérêt de Finsler-MDS pour représenter des dissimilarités asymétriques issues de données biologiques, mais indiquent aussi que les extensions géodésiques et les métriques plus riches doivent être testées sur d’autres jeux de données ou avec des procédures d’optimisation plus robustes.

6 Conclusion et perspectives

Ce pré-rapport a présenté notre travail sur deux extensions de Finsler-MDS, une méthode de réduction de dimension visant à représenter des dissimilarités asymétriques. La première

consiste à remplacer la métrique de Randers canonique par la métrique de Matsumoto, afin d'étudier si une géométrie de Finsler plus riche peut mieux représenter certaines dissimilarités asymétriques. La seconde consiste à remplacer les distances directes dans l'espace d'arrivée par des distances géodésiques, donnant lieu à l'extension GeoMDS. Notre objectif était à la fois d'étudier l'intérêt théorique de ces extensions et de proposer des implémentations permettant de les tester en pratique.

La principale contribution théorique concerne l'étude de Matsumoto dans le cas canonique uniforme. Nous avons montré que, contrairement à Randers uniforme, Matsumoto peut modifier les chemins géodésiques en favorisant les trajectoires de pente régulière. Nous avons aussi identifié des phénomènes d'asymétrie plus marqués, comme la possibilité de chemins optimaux différents selon le sens du déplacement, ainsi que le rôle du régime non convexe $\|\omega\| > 1/2$, où apparaissent des comportements de type zigzag ou lacets. Sur le plan algorithmique, nous avons implémenté GeoMDS en proposant l'algorithme *Path-Frozen Alternating Optimization* accompagné d'heuristiques de passage à l'échelle fondées sur des landmarks, des targets et des paires locales. Nous avons aussi testé des alternatives fondées sur des relaxations différentiables, moins efficaces pour l'instant. Par ailleurs, nous avons corrigé une erreur dans Finsler-SMACOF. Enfin, nos expériences sur cas synthétiques montrent que GeoMDS peut mieux représenter certaines structures que le MDS direct, tandis que les tests sur le jeu de données Pancreas montrent que Finsler-MDS utilisant Randers ou Matsumoto peut être appliqué à des données réelles de RNA-velocity et améliore certaines métriques directionnelles par rapport au MDS standard.

Ces résultats restent cependant partiels. Matsumoto possède des propriétés géométriques plus riches que Randers, mais les expériences actuelles ne montrent pas encore de cas où cette richesse se traduit par un gain pratique net. Dans les tests biologiques, Matsumoto donne souvent des résultats proches de Randers, avec un compromis légèrement différent entre les métriques. De même, GeoMDS apporte un gain clair sur certains cas synthétiques, mais reste plus coûteux et moins robuste que les méthodes à distances directes, l'objectif avec distances géodésiques étant plus complexe. Les résultats sur Pancreas montrent aussi que cette extension géodésique n'est pas automatiquement bénéfique sur un jeu de données réel donné.

Le mois restant du stage sera consacré à consolider ces résultats expérimentaux. Une priorité sera de poursuivre les tests biologiques, en particulier sur l'inférence de trajectoire, où les distances de chemin dans l'embedding ont une motivation naturelle mais où nos résultats restent très préliminaires. Nous chercherons notamment à utiliser des jeux de données disposant d'un pseudotime ou d'annotations temporelles plus explicites. Les expériences sur RNA-velocity devront également être complétées, en particulier dans le cadre des embeddings 3D. En parallèle, nous continuerons à raffiner l'implémentation de GeoMDS, notamment autour de Path-Frozen et de ses paramètres d'optimisation. Enfin, nous chercherons à construire un cas synthétique plus robuste pour évaluer l'avantage expérimental éventuel de Matsumoto par rapport à Randers dans GeoMDS. Ces compléments devraient permettre de préciser dans quels contextes les extensions développées apportent un gain réel, et dans lesquels le Finsler-MDS standard reste la solution la plus adaptée.

Références

- Aleksandr Y. Aravkin, James V. Burke, Dmitriy Drusvyatskiy, Michael P. Friedlander, and Kellie J. MacPhee. Foundations of gauge and perspective duality. *SIAM Journal on Optimization*, 28(3) :2406–2434, 2018. doi : 10.1137/17M1132364.
- Lyla Atta, Arpan Sahoo, and Jean Fan. VeloViz : RNA-velocity informed 2d embeddings for visualizing cellular trajectories. *Bioinformatics*, 38(2) :391–396, 2022. doi : 10.1093/bioinformatics/btab653. Published online 2021.
- David Bao, Colleen Robles, and Zhongmin Shen. Zermelo navigation on riemannian manifolds. *Journal of Differential Geometry*, 66(3) :377–435, 2004. doi : 10.4310/jdg/1098137838.
- Aimée Bastidas-Ponce, Sophie Tritschler, Leander Dony, Katharina Scheibner, Maria Tarquis-Medina, Caterina Salinno, Sandra Schirge, Ingo Burtscher, Anika Böttcher, Fabian J. Theis, Heiko Lickert, and Mostafa Bakhti. Comprehensive single cell mrna profiling reveals a detailed roadmap for pancreatic endocrinogenesis. *Development*, 146(12) :dev173849, 2019. doi : 10.1242/dev.173849.
- Richard Bellman. On a routing problem. *Quarterly of Applied Mathematics*, 16(1) :87–90, 1958. doi : 10.1090/qam/102435.
- Volker Bergen, Marius Lange, Stefan Peidli, F. Alexander Wolf, and Fabian J. Theis. Generalizing RNA velocity to transient cell states through dynamical modeling. *Nature Biotechnology*, 38 : 1408–1414, 2020. doi : 10.1038/s41587-020-0591-3.
- Amit Bracha, Thomas Dagès, and Ron Kimmel. Wormhole loss for partial shape matching. In *Advances in Neural Information Processing Systems*, volume 37, pages 131247–131277, 2024.
- Junyue Cao, Malte Spielmann, Xiaojie Qiu, Xingfan Huang, Daniel M. Ibrahim, Andrew J. Hill, Fan Zhang, Stefan Mundlos, Lena Christiansen, Frank J. Steemers, Cole Trapnell, and Jay Shendure. The single-cell transcriptional landscape of mammalian organogenesis. *Nature*, 566(7745) :496–502, 2019. doi : 10.1038/s41586-019-0969-x.
- P. Chansri, P. Chansangiam, and Sorin V. Sabau. The geometry on the slope of a mountain. *Miskolc Mathematical Notes*, 21(2) :747–762, 2020. doi : 10.18514/MMN.2020.3335.
- Da Chen, Jean-Marie Mirebeau, and Laurent D. Cohen. Global minimum for a Finsler elastica minimal path approach. *International Journal of Computer Vision*, 122(3) :458–483, 2017. doi : 10.1007/s11263-016-0975-5.
- Thomas Dagès, Michael Lindenbaum, and Alfred M. Bruckstein. Metric convolutions : A unifying theory to adaptive image convolutions. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 13974–13984, 2025a.
- Thomas Dagès, Simon Weber, Ya-Wei Eileen Lin, Ronen Talmon, Daniel Cremers, Michael Lindenbaum, Alfred M. Bruckstein, and Ron Kimmel. Finsler multi-dimensional scaling : Manifold learning for asymmetric dimensionality reduction and embedding. In *Proceedings*

- of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 25842–25853, 2025b. doi : 10.1109/CVPR52734.2025.02407.
- Thomas Dagès, Simon Weber, Daniel Cremers, and Ron Kimmel. Harnessing data asymmetry : Manifold learning in the Finsler world. *arXiv preprint arXiv :2603.11396*, 2026. URL <https://arxiv.org/abs/2603.11396>.
- Jan de Leeuw. Applications of convex analysis to multidimensional scaling. In J. R. Barra, F. Brodeau, G. Romier, and B. Van Cutsem, editors, *Recent Developments in Statistics*, pages 133–146. North-Holland, Amsterdam, 1977.
- Jan de Leeuw and Patrick Mair. Multidimensional scaling using majorization : SMACOF in R. *Journal of Statistical Software*, 31(3) :1–30, 2009. doi : 10.18637/jss.v031.i03.
- Vin de Silva and Joshua B. Tenenbaum. Sparse multidimensional scaling using landmark points. Technical report, Stanford University, 2004.
- Michaël Fanuel, Carlos M. Alaíz, Ángela Fernández, and Johan A. K. Suykens. Magnetic eigenmaps for the visualization of directed networks. *Applied and Computational Harmonic Analysis*, 44(1) :189–199, 2018. doi : 10.1016/j.acha.2017.01.004.
- Françoise François, Ilkka Kivimäki, Amin Mantrach, Fabrice Rossi, and Marco Saerens. A bag-of-paths framework for network data analysis. *Neural Networks*, 90 :90–111, 2017. doi : 10.1016/j.neunet.2017.02.009.
- Barak Gahtan, Jacob Shpund, and Alex M. Bronstein. Wildfire simulation with differentiable Randers-Finsler eikonal solvers. *arXiv preprint arXiv :2603.00035*, 2026. doi : 10.48550/arXiv.2603.00035.
- Harold Hotelling. Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24(6–7) :417–441, 498–520, 1933. Two-part article.
- Joseph B. Kruskal. Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis. *Psychometrika*, 29(1) :1–27, 1964. doi : 10.1007/BF02289565.
- Gioele La Manno, Ruslan Soldatov, Amit Zeisel, Emelie Braun, Hannah Hochgerner, Viktor Petukhov, Katja Lidschreiber, Maria E. Kastriti, Peter Lönnerberg, Alessandro Furlan, Jean Fan, Lars E. Borm, Zehua Liu, David van Bruggen, Jimin Guo, Xiaoling He, Roger Barker, Erik Sundström, Gonçalo Castelo-Branco, Patrick Cramer, Igor Adameyko, Sten Linnarsson, and Peter V. Kharchenko. RNA velocity of single cells. *Nature*, 560(7719) :494–498, 2018. doi : 10.1038/s41586-018-0414-6.
- Alan A. Lahoud, Erik Schaffernicht, and Johannes A. Stork. DataSP : A differential all-to-all shortest path algorithm for learning costs and predicting paths with context. *arXiv preprint arXiv :2405.04923*, 2024. URL <https://arxiv.org/abs/2405.04923>.
- Makoto Matsumoto. A slope of a mountain is a Finsler surface with respect to a time measure. *Journal of Mathematics of Kyoto University*, 29(1) :17–25, 1989. doi : 10.1215/kjm/1250520303.

- Leland McInnes, John Healy, and James Melville. UMAP : Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv :1802.03426*, 2018. URL <https://arxiv.org/abs/1802.03426>.
- Alberto E. Minetti, Christian Moia, Giulio S. Roi, Davide Susta, and Guido Ferretti. Energy cost of walking and running at extreme uphill and downhill slopes. *Journal of Applied Physiology*, 93(3) :1039–1046, 2002. doi : 10.1152/japplphysiol.01177.2001.
- Kevin R. Moon, David van Dijk, Zheng Wang, Scott Gigante, Daniel B. Burkhardt, William S. Chen, Kristina Yim, Antonia van den Elzen, Matthew J. Hirn, Ronald R. Coifman, Natalia B. Ivanova, Guy Wolf, and Smita Krishnaswamy. Visualizing structure and transitions in high-dimensional biological data. *Nature Biotechnology*, 37 :1482–1492, 2019. doi : 10.1038/s41587-019-0336-3.
- Akinori Okada and Tadashi Imaizumi. Nonmetric multidimensional scaling of asymmetric proximities. *Behaviormetrika*, 14(21) :81–96, 1987. doi : 10.2333/bhmk.14.21_81.
- Mingdong Ou, Peng Cui, Jian Pei, Ziwei Zhang, and Wenwu Zhu. Asymmetric transitivity preserving graph embedding. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1105–1114, 2016. doi : 10.1145/2939672.2939751.
- Franziska Paul, Ya’ara Arkin, Amir Giladi, Diego Adhemar Jaitin, Ephraim Kenigsberg, Hadas Keren-Shaul, Deborah Winter, David Lara-Astiaso, Meital Gury, Assaf Weiner, Eyal David, Nadav Cohen, Felicia Kathrine Bratt Lauridsen, Simon Haas, Andreas Schlitzer, Alexander Mildner, Florent Ginhoux, Steffen Jung, Andreas Trumpp, Bo Torben Porse, Amos Tanay, and Ido Amit. Transcriptional heterogeneity and lineage commitment in myeloid progenitors. *Cell*, 163(7) :1663–1677, 2015. doi : 10.1016/j.cell.2015.11.013.
- Karl Pearson. On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11) :559–572, 1901. doi : 10.1080/14786440109462720.
- Dominique C. Perrault-Joncas and Marina Meila. Directed graph embedding : an algorithm based on continuous limits of Laplacian-type operators. In *Advances in Neural Information Processing Systems*, volume 24, 2011.
- Chen Qiao and Yuanhua Huang. Representation learning of rna velocity reveals robust cell transitions. *Proceedings of the National Academy of Sciences*, 118(49) :e2105859118, 2021. doi : 10.1073/pnas.2105859118.
- Gunnar Randers. On an asymmetrical metric in the four-space of general relativity. *Physical Review*, 59(2) :195–199, 1941. doi : 10.1103/PhysRev.59.195.
- T. Mitchell Roddenberry and Richard G. Baraniuk. Finsler geometry, graph neural networks, and you. *arXiv preprint arXiv :2606.17185*, 2026. doi : 10.48550/arXiv.2606.17185.
- Zhongmin Shen. *Lectures on Finsler Geometry*. World Scientific, 2001.

- Roger N. Shepard. The analysis of proximities : Multidimensional scaling with an unknown distance function. I. *Psychometrika*, 27(2) :125–140, 1962. doi : 10.1007/BF02289630.
- Charles Spearman. The proof and measurement of association between two things. *The American Journal of Psychology*, 15(1) :72–101, 1904. doi : 10.2307/1412159.
- Joshua B. Tenenbaum, Vin de Silva, and John C. Langford. A global geometric framework for nonlinear dimensionality reduction. *Science*, 290(5500) :2319–2323, 2000. doi : 10.1126/science.290.5500.2319.
- Waldo R. Tobler. Three presentations on geographical analysis and modeling. In *Non-Isotropic Geographic Modeling*. National Center for Geographic Information and Analysis, Santa Barbara, CA, 1993.
- Warren S. Torgerson. Multidimensional scaling : I. theory and method. *Psychometrika*, 17(4) : 401–419, 1952. doi : 10.1007/BF02288916.
- Cole Trapnell, Davide Cacchiarelli, Jonna Grimsby, Prapti Pokharel, Shuqiang Li, Michael Morse, Niall J. Lennon, Kenneth J. Livak, Tarjei S. Mikkelsen, and John L. Rinn. The dynamics and regulators of cell fate decisions are revealed by pseudotemporal ordering of single cells. *Nature Biotechnology*, 32 :381–386, 2014. doi : 10.1038/nbt.2859.
- Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9 :2579–2605, 2008. URL <https://www.jmlr.org/papers/v9/vandermaaten08a.html>.
- Simon Weber, Thomas Dagès, Maolin Gao, and Daniel Cremers. Finsler-laplace-beltrami operators with application to shape analysis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 3131–3140, 2024.
- F. Alexander Wolf, Fiona K. Hamey, Mireya Plass, Jordi Solana, Joakim S. Dahlin, Berthold Göttgens, Nikolaus Rajewsky, Lukas Simon, and Fabian J. Theis. PAGA : Graph abstraction reconciles clustering with trajectory inference through a topology preserving map of single cells. *Genome Biology*, 20(59), 2019. doi : 10.1186/s13059-019-1663-x.
- Yujia Xie, Hanjun Dai, Minshuo Chen, Bo Dai, Tuo Zhao, Hongyuan Zha, Wei Wei, and Tomas Pfister. Differentiable top-k operator with optimal transport. In *Advances in Neural Information Processing Systems*, volume 33, pages 20520–20531, 2020.

Annexes

A Modèles de marche de Tobler et Minetti

Cette annexe précise les deux modèles de marche évoqués en section 3.2. Ils ne sont pas utilisés dans nos algorithmes, mais ils permettent de situer Matsumoto par rapport à des modèles plus proches de la marche humaine.

La fonction de Tobler donne empiriquement une vitesse de marche en fonction de la pente [Tobler, 1993] :

$$v(\alpha) = 6 \exp(-3.5|\tan(\alpha) + 0.05|),$$

où α désigne l'inclinaison de la pente. Cette formule prédit une vitesse maximale pour une légère descente, et une vitesse qui diminue fortement lorsque la pente devient trop positive ou trop négative. En considérant que le temps de parcours est inversement proportionnel à cette vitesse, on peut définir un coût de déplacement normalisé par

$$|u| \frac{v(0)}{v(\alpha)}.$$

En remplaçant v par l'expression de Tobler, cela donne une fonction de coût de la forme

$$F_T(u) = |u| \exp(3.5(|\tan(\alpha) + 0.05| - 0.05)).$$

Le modèle de Minetti part quant à lui d'un coût énergétique mesuré expérimentalement en fonction de la pente [Minetti et al., 2002]. Dans la paramétrisation usuelle, ce coût est approché par un polynôme C de degré 5 appliqué à la pente $\tan(\alpha)$. En supposant une puissance fournie constante, ce coût énergétique peut être converti en temps de parcours. Dans notre convention, et en tenant compte du domaine expérimental $|\tan(\alpha)| < 0.45$, on peut écrire

$$F_{Mi}(u) = \begin{cases} |u| \frac{C(\tan(\alpha))}{C(0)} & \text{si } |\tan(\alpha)| < 0.45, \\ +\infty & \text{sinon.} \end{cases}$$

Ces deux modèles sont plus réalistes que Matsumoto pour représenter la marche humaine sur une vraie pente. Tobler et Minetti pénalisent les montées trop raides, mais aussi les descentes trop fortes, ce qui correspond mieux à l'intuition physique d'un marcheur devant ralentir ou devenir incapable de descendre une pente extrême. Cette différence apparaît dans les disques unité de la figure 16 : les directions verticales ou trop inclinées sont fortement pénalisées, voire interdites.

Ces propriétés sont cependant moins adaptées à notre objectif. Dans Finsler-MDS, l'espace




FIGURE 16 – Comparaison qualitative de disques unité associés à Randers, Matsumoto, Tobler et Minetti. Tobler et Minetti ont des formes plus proches d’une marche réelle, mais plus difficiles à exploiter dans notre cadre algorithmique.


d’arrivée est un embedding abstrait. Les directions très inclinées ne correspondent donc pas nécessairement à des pentes physiques dangereuses. Interdire ou pénaliser fortement certaines directions peut alors être contre-intuitif, et rend l’optimisation plus difficile. Par ailleurs, les expressions de Tobler et Minetti sont moins simples que celles de Randers ou Matsumoto, et leurs fonctions de coût ne correspondent d’ailleurs pas à des métriques de Finsler régulières. Pour ces raisons, nous les utilisons seulement comme points de comparaison conceptuels, tandis que l’étude principale se concentre sur Matsumoto.

B Mesures sur les heuristiques de Path-Frozen

Cette annexe présente les mesures utilisées pour comparer les heuristiques de passage à l’échelle de Path-Frozen. Pour chaque configuration, nous avons lancé Path-Frozen en mesurant le temps d’exécution total. Toutes les quelques itérations externes, nous avons interrompu le chronomètre pour évaluer le stress géodésique complet, c’est-à-dire le stress calculé sur toutes les paires de points, et non le stress partiel utilisé par les heuristiques de landmarks, targets ou paires locales. Cette évaluation est coûteuse car elle nécessite de recalculer des plus courts chemins depuis toutes les sources, mais elle permet de comparer les méthodes sur le même objectif. Toutes les courbes présentées sont des moyennes sur 10 seeds différentes, avec $N_{\text{inner}} = 20$.

Nous représentons le stress en fonction du temps d’optimisation plutôt qu’en fonction du nombre d’itérations externes. En effet, selon l’heuristique utilisée, une itération externe peut avoir un coût très différent. Fixer seulement le nombre d’itérations externes pourrait donc favoriser artificiellement les méthodes dont les itérations sont plus coûteuses, ou au contraire interrompre trop tôt les méthodes rapides.

Nous utilisons deux jeux de données synthétiques de 1000 points, représentés figure 17. Le premier est un swiss roll avec un effet de courant, donc des dissimilarités asymétriques, que l'article original de Finsler-MDS utilisait. Sa géométrie est relativement simple : l'initialisation est déjà dépliée donc il suffit de l'orienter correctement pour respecter l'asymétrie. Le second est un jeu de données ramifié, sans asymétrie, dont la géométrie est moins triviale et que nous appelons Branching. L'initialisation est suffisamment proche de la structure attendue pour que Path-Frozen puisse en principe la reconstruire, mais cela demande une optimisation plus fine de la structure globale et locale.



(a) Swiss roll avec dissimilarités asymétriques. Seuls 10% des points sont affichés pour plus de clarté visuelle. (b) Jeu de données ramifié "Branching" à gauche, et l'initialisation utilisée à droite.

FIGURE 17 – Jeux de données synthétiques utilisés pour comparer les heuristiques de Path-Frozen.

La figure 18 compare les principales stratégies. La version all-pairs calcule Dijkstra depuis tous les points et optimise le stress sur toutes les paires. Les variantes avec landmarks ne lancent Dijkstra que depuis une fraction des points, et les variantes avec targets limitent en plus le nombre de paires utilisées dans la descente de gradient. Enfin, les variantes avec paires locales ajoutent les paires de voisins des données d'origine, soit avec leur distance géodésique, soit avec une distance directe.

Sur le swiss roll, les stratégies utilisant seulement landmarks et targets réduisent fortement le coût de chaque itération, mais convergent vers un stress nettement plus élevé. L'ajout des paires locales change fortement le comportement : le stress diminue beaucoup plus vite et atteint une limite comparable, voire meilleure que celle obtenue avec toutes les paires. Ce gain est particulièrement net avec les paires locales directes. Une partie de cet effet peut venir du fait que les plus courts chemins sur le swiss roll sont en moyenne longs, ce qui rend le gradient des termes géodésiques plus coûteux et moins local ; les paires directes ajoutent alors un signal local plus stable.

Sur Branching, les landmarks et targets seuls sont déjà plus compétitifs, car les chemins sont en moyenne plus courts et la structure globale est moins étirée. L'ajout des paires locales reste cependant bénéfique, en particulier avec les distances directes, qui permettent de reconstruire




FIGURE 18 – Évolution du stress géodésique complet pour différentes heuristiques de Path-Frozen.

plus rapidement la géométrie fine des branches. Dans les deux cas, la stratégie combinant landmarks, targets et paires locales directes est donc celle qui donne le meilleur compromis entre coût et diminution du stress.

Nous avons aussi comparé le choix aléatoire des landmarks au farthest-point sampling, présenté figure 19. Le farthest-point sampling garantit une meilleure couverture spatiale, mais son avantage n'est pas systématique. Sur le swiss roll, il améliore certaines configurations, notamment avec un nombre suffisant de landmarks. Sur Branching, les différences sont plus faibles et dépendent davantage de la seed. Dans nos expériences principales, nous avons donc conservé un échantillonnage aléatoire simple, plus léger et suffisamment stable lorsque le nombre de landmarks n'est pas trop faible.




FIGURE 19 – Comparaison entre landmarks aléatoires et farthest-point sampling.

Des tests complémentaires montrent que les mêmes heuristiques peuvent être appliquées à Soft-Bellman-Ford, qui travaille aussi à partir d'un ensemble de sources. Cependant, même

avec landmarks, targets et paires locales, Soft-Bellman-Ford reste plus lent et plus délicat à régler que Path-Frozen, notamment à cause du choix du nombre de relaxations et du paramètre de soft-minimum. Cela confirme le choix de Path-Frozen comme méthode principale pour les expériences GeoMDS de ce rapport.

C Métriques d'évaluation pour RNA-velocity

Cette annexe détaille les trois métriques utilisées dans la section 5.3 pour évaluer les embeddings du jeu de données Pancreas. Ces métriques utilisent les coordonnées des cellules dans l'embedding ainsi que les vecteurs de vitesse projetés dans ce même embedding. On note y_i la position de la cellule i dans l'embedding, v_i son vecteur de vitesse projeté, C_A l'ensemble des cellules du cluster A , et $N(i)$ l'ensemble des voisins de i .

La Cross-Boundary Direction correctness (CBDir) mesure si les vecteurs de vitesse aux frontières entre clusters pointent dans la direction des transitions biologiques attendues [Qiao and Huang, 2021]. Pour une transition attendue $A \rightarrow B$, on définit les cellules frontière par

$$C_{A \rightarrow B} = \{i \in C_A \mid N(i) \cap C_B \neq \emptyset\}.$$

Pour une cellule frontière i , le score local est

$$\text{CBDir}_{A \rightarrow B}(i) = \frac{1}{|N(i) \cap C_B|} \sum_{j \in N(i) \cap C_B} \frac{v_i^T (y_j - y_i)}{\|v_i\| \|y_j - y_i\|}.$$

Le score associé à la transition $A \rightarrow B$ est ensuite obtenu en moyennant sur les cellules frontière :

$$\text{CBDir}_{A \rightarrow B} = \frac{1}{|C_{A \rightarrow B}|} \sum_{i \in C_{A \rightarrow B}} \text{CBDir}_{A \rightarrow B}(i).$$

Enfin, le score global est la moyenne sur les transitions connues du jeu de données :

$$\text{CBDir} = \frac{1}{|\mathcal{T}|} \sum_{(A,B) \in \mathcal{T}} \text{CBDir}_{A \rightarrow B},$$

où $\mathcal{T}$ est l'ensemble des transitions biologiques attendues. Cette métrique est donc fondée sur une information de vérité terrain partielle, sous la forme de transitions entre clusters.

L'In-Cluster Velocity Coherence (ICVCoh) mesure la cohérence locale des vitesses à l'intérieur d'un même cluster [Qiao and Huang, 2021]. Pour une cellule $i \in C_A$, on compare son vecteur de vitesse aux vecteurs de vitesse de ses voisins appartenant au même cluster :

$$\text{ICVCoh}(i) = \frac{1}{|N(i) \cap C_A|} \sum_{j \in N(i) \cap C_A} \frac{v_i^T v_j}{\|v_i\| \|v_j\|}.$$

Le score global est obtenu en moyennant sur les cellules pour lesquelles l'ensemble $N(i) \cap C_A$ est non vide :

$$\text{ICVCoh} = \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \text{ICVCoh}(i),$$

où

$$\mathcal{I} = \{i \mid N(i) \cap C(i) \neq \emptyset\},$$

et $C(i)$ désigne le cluster de la cellule i . Contrairement à CBDir, cette métrique n'évalue pas si la direction est biologiquement correcte, mais seulement si les vélocités sont localement cohérentes.

Nous avons aussi introduit la Velocity Alignment Correlation (VAC), afin de mesurer directement si les alignements entre vélocités et directions vers les voisins sont préservés entre l'espace d'origine et l'embedding. On note x_i la position de la cellule i dans l'espace ACP de départ, u_i son vecteur de vélocité dans cet espace, et y_i, v_i leurs projections dans l'embedding. Pour chaque paire de voisins (i, j) considérée, on calcule

$$a_{ij}^{\text{orig}} = \frac{u_i^T (x_j - x_i)}{\|u_i\| \|x_j - x_i\|},$$

et

$$a_{ij}^{\text{emb}} = \frac{v_i^T (y_j - y_i)}{\|v_i\| \|y_j - y_i\|}.$$

La métrique VAC est alors définie comme la corrélation de Spearman entre ces deux familles de cosinus :

$$\text{VAC} = \rho_S \left(\left(a_{ij}^{\text{orig}} \right)_{(i,j) \in E}, \left(a_{ij}^{\text{emb}} \right)_{(i,j) \in E} \right),$$

où E est l'ensemble des paires de voisins utilisées pour l'évaluation. La corrélation de Spearman [Spearman, 1904] est la corrélation de Pearson entre les rangs des deux variables. Elle ne compare donc pas directement les valeurs des cosinus, mais leur ordre relatif. Ce choix est adapté ici, car les angles ne sont pas directement comparables entre l'espace ACP de dimension 50 et un embedding de dimension 2 ou 3 : en grande dimension, les directions ont naturellement tendance à être plus proches de l'orthogonalité. VAC mesure donc plutôt si les voisins les mieux alignés avec la vélocité dans l'espace d'origine restent parmi les mieux alignés dans l'embedding.